



**Universidad Católica Andrés Bello**

**Facultad de Ingeniería**

**Escuela de Ingeniería Informática**

**Sistema de Monitoreo Acústico, para Identificar Sonidos y Generar Alertas de Emergencia**

**Trabajo de Grado**

presentado ante la

**UNIVERSIDAD CATÓLICA ANDRÉS BELLO**

como parte de los requisitos para optar al título de

**INGENIERO EN INFORMÁTICA**

Realizado por

Naim, Carmelo

Sotillo, César

Tutor

Lárez, Jesús

Fecha

Marzo, 2025

## Índice de Contenido

<b>Resumen</b>	<b>VIII</b>
<b>Introducción</b>	<b>1</b>
<b>Capítulo I. El Problema</b>	<b>3</b>
Planteamiento del Problema	3
Objetivos	5
Objetivo General	5
Objetivos Específicos	5
Alcance	5
Limitaciones	6
Justificación	7
<b>Capítulo II. Marco Teórico</b>	<b>8</b>
Antecedentes de la Investigación	8
Real-time Audio Classification on an Edge Device [Clasificación de audio en tiempo real en un dispositivo perimetral]	8
Analysing RMS and peak values of vibration signals for condition monitoring of wind turbine gearboxes [Análisis de valores RMS y pico de señales de vibración para la monitorización del estado de las cajas de engranajes de aerogeneradores]	9
Metodología para la identificación de eventos sonoros anómalos	10
Edge AI for Real-Time Anomaly Detection in Smart Homes [Inteligencia artificial de borde para la detección de anomalías en tiempo real en hogares inteligentes]	10
Bayesian Optimization with Inequality Constraints [Optimización Bayesiana con Restricciones de Desigualdad]	11
Bases Teóricas	12
Dispositivos Edge	12
Raspberry pi	12
Python	13

Tensorflow . . . . .	13
NestJs . . . . .	13
Inteligencia artificial . . . . .	14
Cadenas de Markov . . . . .	15
Agente . . . . .	17
Ciencia de datos . . . . .	17
Técnicas predictivas para series temporales . . . . .	18
Transformers . . . . .	19
LSTM (Long Short-Term Memory) . . . . .	19
Autoencoders . . . . .	20
Isolation Forest (Bosque de Aislamiento) . . . . .	20
Yamnet . . . . .	21
Redis Pub/Sub . . . . .	22
Bases Legales . . . . .	22
<b>Capítulo III. Marco Metodológico . . . . .</b>	<b>24</b>
Tipo de Investigación . . . . .	24
Técnicas e Instrumentos de Recolección de Datos . . . . .	24
Metodología de Desarrollo Utilizada . . . . .	25
<b>Capítulo IV. Desarrollo y Resultados . . . . .</b>	<b>28</b>
Análisis inicial del sistema de monitoreo acústico para generar alertas en casos de emergencia. . . . .	28
Requerimientos Funcionales . . . . .	30
Requerimientos no funcionales . . . . .	30
Procedimiento Metodológico . . . . .	30
Primera Iteracion . . . . .	30
Segunda Iteracion . . . . .	32
Tercera iteración . . . . .	33
Cuarta Iteración . . . . .	34
Quinta Iteración . . . . .	36
Evaluacion de los Modelos . . . . .	39

Evaluacion del LSTM Autoencoder . . . . .	39
Evaluacion del Isolation Forest . . . . .	44
Sexta Iteración . . . . .	48
Evaluacion del LSTM Autoencoder V2 . . . . .	49
Diseño final de la arquitectura del sistema . . . . .	52
Selección de hardware y dispositivos Edge . . . . .	55
<b>Capítulo V. Conclusiones y Recomendaciones . . . . .</b>	<b>57</b>
Conclusiones . . . . .	57
Recomendaciones . . . . .	58
<b>Referencias . . . . .</b>	<b>60</b>
<b>Anexos . . . . .</b>	<b>65</b>
<b>Anexo A. Dispositivo Raspberry Pi 4 Model B . . . . .</b>	<b>66</b>
<b>Anexo B. Construcción del Isolation Forest (Bosque de Aislamiento) . . . . .</b>	<b>67</b>
<b>Anexo C. Numero de datos de entrenamiento por categoría de sonido . . . . .</b>	<b>68</b>
<b>Apéndices . . . . .</b>	<b>80</b>
<b>Apéndice A. Representación cíclica del tiempo mediante funciones trigonométricas . . .</b>	<b>81</b>
<b>Apéndice B. Algoritmos de los distintos agentes . . . . .</b>	<b>83</b>
<b>Apéndice C. Verificación del sistema de monitoreo acústico . . . . .</b>	<b>86</b>
<b>Apéndice D. Cuadro comparativo de microcontroladores . . . . .</b>	<b>88</b>
<b>Apéndice E. Manual de Usuario . . . . .</b>	<b>89</b>
<b>Apéndice F. Manual de Sistema . . . . .</b>	<b>93</b>

## Índice de Tablas

Tabla 1. Cuadro Comparativo de metodologías . . . . .	25
Tabla 2. Matriz de Confusión del LSTM Autoencoder . . . . .	42
Tabla 3. Matriz de Confusión del Isolation Forest . . . . .	45
Tabla 4. Matriz de Confusión del LSTM Autoencoder V2 . . . . .	50
Tabla 5. Requerimientos del sistema acústico . . . . .	87
Tabla 6. Cuadro comparativo de microcontroladores . . . . .	88

## Índice de Figuras

Figura 1. Modelo de desarrollo en espiral propuesto por Boehm (1988). . . . .	27
Figura 2. Prototipo basado en ESP32 y detección de intensidad de sonido . . . . .	31
Figura 3. Diseño de prototipo de esp32 con micrófono de señales de audio y prophet . .	32
Figura 4. Prototipo con Raspberry Pi, Yamnet y Cadenas de Markov . . . . .	34
Figura 5. Curva ROC y AUC del LSTM Autoencoder . . . . .	40
Figura 6. Gráficas de MSE por secuencia para el LSTM Autoencoder. . . . .	41
Figura 7. Gráficas de puntuación de anomalía por evento para el Isolation Forest. . . .	45
Figura 8. Curva ROC y AUC del Isolation Forest. . . . .	47
Figura 9. Parametros originales. . . . .	48
Figura 10. Parametros nuevos. . . . .	49
Figura 11. Curva ROC y AUC del LSTM Autoencoder V2. . . . .	49
Figura 12. Gráficas de MSE por secuencia para el LSTM Autoencoder V2. . . . .	50
Figura 13. Arquitectura del sistema de monitoreo acústico para generar alertas en casos de emergencia . . . . .	53
Figura 14. Arquitectura del Raspberry Pi 4 Model B . . . . .	66
Figura 15. Algoritmo de construcción del Isolation Forest . . . . .	67
Figura 16. Número de datos de entrenamiento por categoría de sonido . . . . .	68
Figura 17. Visualización de las funciones seno y coseno . . . . .	81
Figura 18. Visualización discreta del comportamiento cíclico del tiempo . . . . .	81
Figura 19. Curva paramétrica continua del tiempo sobre el círculo unitario . . . . .	82
Figura 20. Algoritmo del agente de detección de anomalías basado en Isolation Forest . .	83
Figura 21. Algoritmo del agente de predicción basado en LSTM . . . . .	84
Figura 22. Algoritmo del agente de detección de silencio . . . . .	85

## Índice de Fórmulas

Fórmula 1.	Accuracy para LSTM Autoencoder . . . . .	42
Fórmula 2.	Tasa de Error para LSTM Autoencoder . . . . .	42
Fórmula 3.	Recall para LSTM Autoencoder . . . . .	42
Fórmula 4.	Precision para LSTM Autoencoder . . . . .	43
Fórmula 5.	Specificity para LSTM Autoencoder . . . . .	43
Fórmula 6.	F1 Score para LSTM Autoencoder . . . . .	43
Fórmula 7.	Accuracy para Isolation Forest . . . . .	45
Fórmula 8.	Tasa de Error para Isolation Forest . . . . .	46
Fórmula 9.	Recall para Isolation Forest . . . . .	46
Fórmula 10.	Precision para Isolation Forest . . . . .	46
Fórmula 11.	Specificity para Isolation Forest . . . . .	46
Fórmula 12.	F1 Score para Isolation Forest . . . . .	46
Fórmula 13.	Accuracy para LSTM Autoencoder V2 . . . . .	50
Fórmula 14.	Tasa de Error para LSTM Autoencoder V2 . . . . .	51
Fórmula 15.	Recall para LSTM Autoencoder V2 . . . . .	51
Fórmula 16.	Precision para LSTM Autoencoder V2 . . . . .	51
Fórmula 17.	Specificity para LSTM Autoencoder V2 . . . . .	51

**Universidad Católica Andrés Bello**

**Facultad de Ingeniería**

**Escuela de Ingeniería Informática**

**Sistema de Monitoreo Acústico, para Identificar Sonidos y Generar Alertas de Emergencia**

Autor: Naim, Carmelo

Sotillo, César

Tutor Académico: Lárez, Jesús

Fecha: Marzo, 2025

**Resumen**

Este trabajo presenta el desarrollo de un sistema de monitoreo acústico basado en inteligencia artificial, que clasifica sonidos ambientales y genera alertas de emergencia al identificar eventos anómalos en tiempo real que podrían implicar que individuos se encuentren en una posición de vulnerabilidad. En este marco, el proyecto aborda la detección de eventos críticos, como cambios en la rutina o gritos de auxilio, con el fin de ofrecer una herramienta de detección que pueda alertar de forma temprana sobre situaciones anormales que podrían indicar una posición de vulnerabilidad del individuo. El sistema fue desarrollado utilizando dispositivos Edge como Raspberry Pi, integrando modelos preentrenados como YAMNet para clasificación de sonidos y Vosk para detección de palabras clave con modelos propios que perfilan el comportamiento acústico con Isolation Forest, LSTM y Transformers. La metodología empleada está basada en el modelo de desarrollo en espiral, lo cual permitió ciclos iterativos de análisis, diseño, implementación y validación, adaptándose a desafíos técnicos como la variabilidad del entorno sonoro y las limitaciones de hardware. Los resultados evidencian que el sistema es capaz de identificar patrones anómalos de sonido en tiempo real y generar notificaciones automáticas a contactos de emergencia. La solución considera la privacidad del usuario al no almacenar audios y procesar todo localmente. Se concluye que este sistema representa una herramienta ética para el monitoreo de entornos domésticos, alineándose con los Objetivos de Desarrollo Sostenible en salud, bienestar e inclusión tecnológica.



***Palabras clave***— alertas de emergencia, dispositivos Edge, inteligencia artificial, monitoreo acústico, Raspberry Pi.

## **Introducción**

Este trabajo aborda el desarrollo de un sistema distribuido que, mediante el uso de inteligencia artificial, permite la detección de anomalías acústicas como herramienta de apoyo para la alerta temprana ante posibles emergencias. El sistema está enfocado en servir no solo a personas mayores o con discapacidades, sino también a cualquier individuo que se encuentre en una condición de vulnerabilidad. Su funcionamiento se basa en dispositivos que primero clasifican los sonidos ambientales en tiempo real para, posteriormente, analizar la secuencia de dichas clasificaciones. Este análisis permite al sistema caracterizar el comportamiento acústico “normal” de un entorno y, en consecuencia, identificar eventos que se desvían de esa normalidad para generar una alerta a contactos predefinidos. La importancia de este proyecto radica en su capacidad de alertar sobre situaciones anormales que podrían indicar una situación de emergencia, ofreciendo un sistema de alerta temprana que respeta la privacidad. Además, tiene el potencial de beneficiar a familias, cuidadores e instituciones y facilitar una intervención más oportuna de los servicios de emergencia, incluso en casos de violencia doméstica o el monitoreo de personas con depresión. A través de la identificación de situaciones anormales y la emisión de alertas, este sistema contribuye a una mejor calidad de vida.

Para el desarrollo del sistema, se empleó una metodología basada en el modelo de desarrollo en espiral, que permite un enfoque iterativo y flexible. Cada ciclo del proceso abarca fases de planificación, análisis de riesgos, desarrollo y evaluación, permitiendo ajustes continuos en el diseño y la implementación del sistema. Esta metodología es adecuada para proyectos con incertidumbre, ya que facilita la evolución del sistema según la retroalimentación obtenida, asegurando su mejora progresiva a lo largo del desarrollo.

El presente trabajo está estructurado en cinco capítulos, En el Capítulo I, referido al Planteamiento del Problema, se describe la problemática, se establecen los objetivos, justificación, alcance y limitaciones del proyecto. En el Capítulo II, se expone el Marco Teórico donde se recopilan los antecedentes y las bases teóricas que sustentan el trabajo. En el Capítulo III, se presenta el Marco Metodológico, que describe el tipo de investigación, técnicas e instrumentos de recolección de datos, metodología de desarrollo y el procedimiento metodológico. En el Capítulo IV, se expone el Desarrollo y Resultados, donde se describe como el procedimiento metodológico dio respuesta a cada uno de los objetivos planteados, y en el Capítulo V, se presentan las conclusiones y recomendaciones sobre el trabajo realizado. Finalmente se listan las

referencias bibliográficas utilizadas, seguidas de los anexos y apéndices.

## **Capítulo I. El Problema**

### **Planteamiento del Problema**

En la actualidad, existe un número significativo de casos de personas que sufrieron algún accidente o complicación de una condición de salud, producto de la detección tardía de estos eventos, una tendencia que ha ido en aumento debido al envejecimiento de la población, que de acuerdo a lo expuesto por la CEPAL (2005), dice que: “el envejecimiento demográfico en América Latina se triplicará entre el 2000 y 2050, con un aumento significativo en la proporción de personas mayores de 60 años” y a la estructura familiar moderna, que según Peña (2016), “El aumento de los hogares unipersonales se ha convertido en un fenómeno extendido dentro del mundo occidental desarrollado”. Esta situación, expone a las personas a múltiples riesgos, especialmente cuando se enfrentan a emergencias domésticas, problemas de salud o accidentes que comprometen su bienestar físico y emocional. La falta de asistencia inmediata en situaciones críticas puede transformar un incidente inicialmente manejable en una amenaza grave para la vida.

Algunos casos ilustran estos riesgos. Un ejemplo es el de un hombre octogenario en Zaragoza, España, cuyo fallecimiento en su domicilio pasó desapercibido durante una semana. No fue hasta que una vecina notó su ausencia que se alertó a las autoridades. Aunque la causa de su muerte fue natural, este caso pone en evidencia la vulnerabilidad de las personas que viven solas y la falta de un mecanismo que pueda detectar la inactividad prolongada o cambios abruptos en la rutina diaria (Ralla, 2024). En una situación como esta, el problema no es la atención médica, sino la ausencia de una alerta automática que notifique una anomalía grave (la total falta de actividad) a familiares o servicios de emergencia. De forma similar, en un caso no fatal como una caída, la falta de esa misma alerta inmediata sí puede derivar en graves complicaciones físicas, transformando un accidente manejable en una crisis de salud. Estos incidentes no son excepcionales, sino que representan una problemática real, especialmente en el contexto de los hogares unipersonales.

El envejecimiento de la población es un fenómeno natural que está incrementando la cantidad de personas mayores que viven en solitario. De acuerdo a lo comentado por la Naciones Unidas (2022): “se estima que para el 2050, el 16 % de la población mundial estará compuesta por personas mayores de 65 años, muchas de las cuales optarán o se verán forzadas a vivir sin compañía”. Esta tendencia plantea un desafío crítico en cuanto a su seguridad y bienestar. La falta de asistencia oportuna en emergencias no solo

representa una vulnerabilidad significativa para la vida de estas personas ante eventos que pongan en riesgo su vida o integridad física, sino que, a largo plazo, puede contribuir a un deterioro progresivo de su estado de salud y autonomía. Además, situaciones como caídas, ataques cardíacos o accidentes domésticos, que podrían ser atendidos a tiempo, se convierten en amenazas letales debido a la ausencia de un sistema de detección temprana.

Aunque en los últimos años se han desarrollado algunas soluciones tecnológicas para abordar esta problemática, como el dispositivo Zoe Fall, que detecta caídas a través de ondas WiFi, o el Apple Watch, que incluye una función de detección de caídas, estas tecnologías no son accesibles para todos ni cubren una gama suficientemente amplia de emergencias. De acuerdo a lo comentado por Carmona (2024): “estas herramientas están mayormente enfocadas en eventos puntuales, como caídas, pero no proporcionan un monitoreo continuo y adaptable a otras situaciones que podrían requerir detección temprana”. Adicionalmente, la mayoría de estos dispositivos dependen de la capacidad del usuario para activarlos o configurarlos adecuadamente, lo cual representa una barrera tecnológica en personas que, por su edad o condición, pueden no estar familiarizadas con el uso de la tecnología.

La falta de mecanismos efectivos para detectar emergencias a tiempo no solo prolongará el sufrimiento de las personas en situaciones críticas, sino que también incrementará las tasas de mortalidad y discapacidad asociadas a estos eventos. La inacción en este sentido implicaría ignorar las necesidades de una población vulnerable, cuya seguridad y calidad de vida pueden verse directamente influenciadas por la imposibilidad de notificar estos eventos.

Ante este panorama, se evidencia la necesidad de desarrollar una solución tecnológica que supere las limitaciones de los dispositivos actuales, ofreciendo un monitoreo más integral, no invasivo y accesible. Por lo tanto, este trabajo se centra en investigar y proponer un sistema de monitoreo inteligente basado en el análisis del entorno acústico. La pregunta central que guía esta investigación es: ¿Es posible, utilizando inteligencia artificial en dispositivos de bajo costo, crear un sistema que caracterice el comportamiento sonoro habitual de un hogar y genere alertas fiables ante patrones anómalos, respetando al mismo tiempo la privacidad del usuario?

Este sistema, ofrecerá un monitoreo continuo, creando un perfil acústico de cada ambiente del hogar que permitirá diferenciar entre sonidos típicos y atípicos en cada entorno.

Al clasificar un sonido que se salga de los patrones típicos, el sistema enviará una consulta al individuo para confirmar si está en buen estado; en caso de no recibir respuesta o de que se confirme una situación de emergencia, enviará una alerta inmediata a los contactos de emergencia predefinidos.

Esto permite generar un perfil de audio adaptado a cada entorno del hogar, ya sea de una persona mayor, una persona con discapacidad, un hogar con muchos niños, o un entorno con vecinos que escuchan música alta con frecuencia. Este perfil facilita la detección de situaciones anómalas que puedan representar un riesgo, especialmente en viviendas donde viven personas solas, quienes pueden enfrentar desafíos por la falta de compañía o asistencia. Así, el sistema está diseñado no solo para adultos mayores o personas con discapacidad, sino para cualquier persona en situación de vulnerabilidad.

Esta solución tiene el potencial de reducir los riesgos asociados a la detección tardía de estos eventos, proporcionando a las personas un mayor nivel de seguridad sin comprometer su privacidad.

## **Objetivos**

### **Objetivo General.**

Desarrollar un sistema para generar alertas en casos de emergencia basado en el monitoreo acústico.

### **Objetivos Específicos.**

1. Analizar los conceptos asociados a la analítica de sonidos ambientales identificando los conceptos necesarios para diseñar el sistema.
2. Diseñar un sistema para generar alertas en casos de emergencia basado en el monitoreo acústico en función del análisis realizado.
3. Implementar el sistema para generar alertas en casos de emergencia basado en el monitoreo acústico según el diseño realizado.
4. Validar el sistema para generar alertas en casos de emergencia basado en el monitoreo acústico con respecto al análisis realizado.
5. Elaborar la documentación técnica y guías del usuario y sistema.

## **Alcance**

El proyecto tiene como objetivo desarrollar un sistema de monitoreo acústico que profile el comportamiento de los habitantes de una vivienda, a través del reconocimiento y clasificación de los

sonidos ambientales en las diferentes estancias de la misma. El sistema generará alarmas en tiempo real que alertarán a contactos de emergencia predefinidos. Para ello se llevará a cabo un análisis de los conceptos asociados a la analítica de sonidos donde se identificarán los conceptos necesarios para diseñar el sistema.

Con base en los resultados del análisis, se procede a diseñar el sistema de monitoreo acústico capaz de reconocer sonidos. El diseño comprende la definición de la arquitectura del sistema, contemplando los componentes esenciales, como la red de micrófonos para la captura de sonidos y los mecanismos de alerta, detección de anomalías y de reconocimiento acústico. El diseño considera la importancia de la privacidad de los usuarios. Según los resultados del análisis realizado para el desarrollo del sistema de monitoreo acústico, se evalúa si es necesario crear un dataset desde cero, obtener uno de internet y modificarlo según sea necesario, o bien emplear un modelo ya preentrenado.

Una vez completado el diseño, se procede a la implementación del sistema de monitoreo acústico. Esta fase incluye la configuración e instalación de los componentes físicos, como los micrófonos distribuidos en las estancias de la vivienda, asegurando una cobertura adecuada para la captura de sonidos relevantes. Los algoritmos de procesamiento de señales y los modelos de inteligencia artificial, definidos en la fase de diseño, fueron desarrollados y adaptados para realizar el reconocimiento y clasificación de los sonidos.

Se desarrollaron los mecanismos de alerta y notificación, que emiten avisos a los contactos de emergencia predefinidos.

Luego se realiza la validación del sistema, se lleva a cabo pruebas funcionales en ambientes controlados y no controlados para comparar los resultados obtenidos con los objetivos planteados y realizar ajustes en caso de ser necesario.

Finalmente se elabora la documentación del sistema, manuales de usuario, manuales de sistema, descripción de los componentes, diagramas y cualquier otro documento necesario.

## **Limitaciones**

En la implementación del sistema, ciertas limitaciones que podrían influir en el desempeño de su desarrollo. A continuación, se describirán algunas de las restricciones que se podrían presentar:

Limitaciones tecnológicas: La precisión del sistema podrá verse afectada por la calidad de los sensores acústicos y la capacidad de procesamiento de los microcontroladores empleados.

Limitaciones de datos: La recolección de suficientes muestras de sonidos para entrenar el modelo

puede ser limitada, lo que puede comprometer el correcto funcionamiento del sistema en escenarios no previstos.

Limitaciones operativas: La inestabilidad del suministro eléctrico, especialmente en contextos donde se realizaron las pruebas, puede interrumpir la recolección continua de datos y afectar la disponibilidad del sistema para capturar eventos clave en su contexto temporal.

Limitaciones de hardware: El reentrenamiento de modelos complejos, como los basados en Transformers o LSTM, requiere recursos de cómputo significativos que superan la capacidad de dispositivos de bajo consumo como Raspberry Pi. Esto restringe la posibilidad de actualizar o adaptar los modelos directamente en el dispositivo, obligando a depender de un servidor externo para estas tareas.

## **Justificación**

En la actualidad, la atención a personas en condiciones de vulnerabilidad justifica el desarrollo de soluciones tecnológicas que permitan una respuesta rápida ante situaciones críticas, sin comprometer la privacidad ni depender de una supervisión constante.

Desde una perspectiva social, el sistema puede beneficiar a personas que, por condiciones físicas o emocionales, se encuentran en mayor riesgo de enfrentar emergencias sin posibilidad de pedir ayuda inmediata, como en casos de caídas, crisis de salud o situaciones de violencia doméstica. También contribuye a la labor de cuidadores y servicios de emergencia al ofrecer alertas tempranas.

En el ámbito institucional, el proyecto plantea una solución aplicable en hogares de cuidado, hospitales o comunidades, ya que su arquitectura de bajo costo y su implementación con componentes disponibles permiten su adaptación a contextos con recursos limitados. Esta característica puede ser relevante en la formulación de futuras regulaciones públicas que busquen integrar herramientas automatizadas en estrategias de atención ciudadana.

El sistema se vincula con los Objetivos de Desarrollo Sostenible (ODS), particularmente el ODS 3: Salud y bienestar, al aportar un mecanismo de alerta temprana en situaciones críticas, y el ODS 10: Reducción de desigualdades, al ofrecer una solución técnica accesible que no depende de infraestructura compleja. Su diseño se considera adaptable por ser independiente del ambiente donde se implemente, lo que lo hace funcional en diferentes contextos sociales, promoviendo mayor equidad en el acceso a herramientas de apoyo.



## **Capítulo II. Marco Teórico**

Este capítulo presenta las bases teóricas y las investigaciones previas que sustentan el desarrollo del Sistema de Monitoreo Acústico para Identificar Sonidos y Generar Alertas de Emergencia. A través de la revisión de fuentes documentales, se exponen los conceptos y enfoques principales relacionados con el procesamiento de señales acústicas, la clasificación de sonidos mediante técnicas de inteligencia artificial y los sistemas de alertas automatizadas.

El marco teórico no solo proporciona un contexto académico para el proyecto, sino que también justifica las decisiones técnicas y metodológicas adoptadas en el diseño del sistema. En las siguientes secciones se detallan los antecedentes investigativos, los modelos de IA aplicados a la clasificación de sonidos y los fundamentos teóricos que permiten la generación de alertas en situaciones de emergencia.

En las siguientes secciones se detallan los antecedentes y los conceptos clave que sustentan este trabajo.

### **Antecedentes de la Investigación**

#### **Real-time Audio Classification on an Edge Device [Clasificación de audio en tiempo real en un dispositivo perimetral].**

Malmberg y Radszuweit (2021) Abordan la implementación de modelos de aprendizaje automático en dispositivos edge para la clasificación de audio en tiempo real, Se centra en el uso del modelo YAMNet, que fue reentrenado para detectar eventos acústicos como disparos, rotura de cristales, animales y habla humana. Este modelo puede desplegarse en dispositivos edge en su versión completa con TensorFlow como en versiones compactas con TensorFlow Lite, con el objetivo de comparar la precisión, el tiempo de inferencia y el uso de memoria de cada variante.

Con el propósito de evaluar el desempeño, trabajaron en una serie de experimentos en los que compararon la precisión del modelo en ambas versiones de TensorFlow. Se encontraron con que, aunque existía una pérdida de precisión en la versión lite los resultados eran comparables a los de la versión completa. Esto implica que TensorFlow Lite es una opción viable y crea la posibilidad de trabajar con

dispositivos de bajo consumo y recursos limitados como ESP32

Este enfoque no solo demuestra la factibilidad de implementar modelos de clasificación de audio en tiempo real en entornos con recursos restringidos, sino que también abre la puerta a futuras investigaciones que busquen mejorar estos modelos. La capacidad de desplegar soluciones de inteligencia artificial en dispositivos edge amplía las posibilidades de aplicaciones en áreas como la seguridad, la vigilancia y el monitoreo ambiental, permitiendo respuestas más rápidas y reduciendo la dependencia de infraestructuras centralizadas.

**Analysing RMS and peak values of vibration signals for condition monitoring of wind turbine gearboxes [Análisis de valores RMS y pico de señales de vibración para la monitorización del estado de las cajas de engranajes de aerogeneradores].**

Igba, Alemzadeh, Durugbo, y Eiriksson (2016) abordan el monitoreo de condición en aerogeneradores con el objetivo de detectar fallos en las cajas de engranajes mediante el análisis de valores RMS y picos de vibraciones. La investigación propone tres modelos: correlación de señales, vibración extrema e intensidad RMS, validados con datos en dominio del tiempo. A través del uso de la teoría de valores extremos, se identificaron indicadores que permiten detectar fallos en etapas tempranas, lo que facilita la planificación del mantenimiento y minimiza el tiempo de inactividad de los aerogeneradores. Los resultados demostraron que el monitoreo de vibraciones proporciona información clave sobre el estado de los componentes y que la precisión de cada técnica depende de la física de la falla, sugiriendo un enfoque integral que combine distintas estrategias para una evaluación más robusta de la salud de los aerogeneradores.

El uso del valor RMS en este estudio es fundamental para la monitorización de la condición de las cajas de engranajes en aerogeneradores, ya que permite evaluar el nivel global de vibración y detectar fallos progresivos, como el desgaste de rodamientos y grietas en ejes. Igba y cols. (2016) destacan que el RMS es una métrica confiable para identificar tendencias anómalas en las vibraciones, lo que facilita la detección temprana de fallos antes de que se conviertan en problemas críticos. A pesar de ciertas limitaciones, como su menor sensibilidad a fallos incipientes en los dientes de los engranajes, el análisis de RMS sigue siendo un pilar clave en la estrategia de mantenimiento basado en condición (CBM), al proporcionar información valiosa sobre la evolución del estado de los componentes mecánicos.

### **Metodología para la identificación de eventos sonoros anómalos.**

Torija, Ruiz, y Ramos-Diao (2018) presentan una metodología para la detección de eventos sonoros anómalos en entornos urbanos. Su trabajo se centra en el análisis de sucesos acústicos que generan incrementos bruscos de energía sonora en el paisaje sonoro urbano, lo que puede provocar molestias significativas en la población expuesta. Según los autores, los eventos sonoros anómalos, como bocinas, gritos, explosiones o disparos, generan una percepción intensificada del ruido ambiental debido a su impacto en la focalización de la atención. Para abordar este problema, desarrollaron un modelo basado en la evaluación del tiempo de estabilización de la medición del ruido ambiental y el análisis del factor cresta, que permite estimar el incremento de energía sonora generado por estos eventos.

El estudio incluyó mediciones en 35 localizaciones de la ciudad de Granada, utilizando un sonómetro Brüel Kjaer tipo 1. La metodología aplicada permitió definir un evento sonoro anómalo como aquel que provoca un incremento del nivel de energía sonora de al menos un 25 % respecto al nivel de fondo caracterizado por el descriptor LA90.

Los resultados indicaron que el número de eventos sonoros anómalos presentes en una ubicación está altamente correlacionado con la variabilidad de la energía sonora en la zona. Además, se evidenció que el factor cresta es un parámetro clave para estimar la magnitud del impacto acústico.

### **Edge AI for Real-Time Anomaly Detection in Smart Homes [Inteligencia artificial de borde para la detección de anomalías en tiempo real en hogares inteligentes].**

Reis y Serôdio (2025) proponen un marco de trabajo para la detección de anomalías en tiempo real en dispositivos de borde (Edge AI), con el objetivo de superar las limitaciones de latencia y privacidad de los sistemas centralizados en la nube. Su enfoque se basa en una arquitectura híbrida que combina dos modelos de aprendizaje automático, Isolation Forest (IF), un modelo ligero para la detección rápida de eventos puntuales, y un Autoencoder de Memoria a Corto y Largo Plazo (LSTM-AE), un modelo de aprendizaje profundo para identificar patrones anómalos en secuencias de datos.

El sistema fue evaluado en plataformas de borde como Raspberry Pi y NVIDIA Jetson Nano para validar su desempeño en entornos con recursos limitados. Con el propósito de evaluar el rendimiento, los autores compararon la precisión de ambos modelos. Los resultados demostraron que el modelo LSTM alcanzó una mayor precisión de detección (hasta un 93.6 %), pero con un costo computacional y energético

más elevado. Un hallazgo clave fue la aplicación de técnicas de cuantización sobre el modelo LSTM, lo que permitió una reducción del 76 % en el tiempo de inferencia y del 35 % en el consumo de energía. Esto confirma que es viable trabajar con versiones ligeras de modelos complejos en dispositivos edge sin sacrificar significativamente la precisión.

Este enfoque no solo demuestra que es posible implementar sistemas de monitoreo de anomalías en tiempo real que sean rápidos, privados y de bajo consumo energético, sino que también subraya la ventaja de una arquitectura híbrida que equilibra velocidad y precisión. La capacidad de desplegar estas soluciones directamente en el hardware del hogar amplía sus aplicaciones a otros dominios como edificios inteligentes e IoT industrial, reduciendo la dependencia de la infraestructura en la nube y permitiendo respuestas más autónomas ante eventos críticos.

### **Bayesian Optimization with Inequality Constraints [Optimización Bayesiana con Restricciones de Desigualdad].**

La Optimización Bayesiana (OB) es un marco de optimización secuencial diseñado para encontrar el mínimo o máximo de funciones que son costosas de evaluar, utilizando un número reducido de iteraciones. A diferencia de métodos tradicionales como la búsqueda en cuadrícula o aleatoria, la optimización bayesiana emplea un modelo sustituto para aproximar la función objetivo y guiar la búsqueda hacia regiones prometedoras del espacio de parámetros Gardner, Kusner, Xu, Weinberger, y Cunningham (2014).

Según Gardner y cols. (2014), este enfoque es especialmente útil en problemas donde cada evaluación de la función implica un alto costo computacional o de tiempo, como en la sintonización de hiperparámetros de modelos de aprendizaje automático o en el diseño de experimentos complejos.

Una extensión importante de este marco es la Optimización Bayesiana con Restricciones de Desigualdad (cBO), que incorpora la evaluación de restricciones igualmente costosas. En este escenario, no solo se busca optimizar una función objetivo, sino también satisfacer una o varias restricciones. La estrategia propuesta por Gardner y cols. combina la mejora esperada con la probabilidad de factibilidad, dando lugar a una función de adquisición restringida que prioriza regiones factibles y prometedoras.

## **Bases Teóricas**

### **Dispositivos Edge.**

El incremento en la demanda de los servicios y aplicaciones en las últimas décadas del uso de la Internet, ha contribuido a un fuerte aumento de los requisitos de procesamiento y almacenamiento de datos. Son diversos, en términos de los recursos que requieren las diferentes aplicaciones y, por lo tanto, a menudo invocan soluciones a medida (Doluí y Kanti Datta, 2017).

Según Medina (2019) Edge Device, en este contexto, se refiere a elementos con capacidades limitadas que tiene su propio conjunto de recursos: CPU, memoria, almacenamiento, y red. Pueden ser Smartphone, Smartglasses, smartwatches, tablets, routers, vehículos autónomos, o cualquier dispositivo de IoT con capacidad de proceso. En este escenario, Edge Computing, representa una solución para enfrentar y aliviar la carga de procesamiento y almacenamiento en la nube, en aplicaciones y tecnologías que requieren de un ancho de banda exponencial y una baja o nula latencia.

Shi, Cao, Zhang, Li, y Xu (2016) definen Edge Computing como un paradigma de computación distribuida que acerca el procesamiento y almacenamiento de datos a la fuente de generación, es decir, al “borde” de la red. Este enfoque permite reducir la latencia, reducir el uso del ancho de banda y mejorar la latencia en aplicaciones que requieren respuestas en tiempo real, como el Internet de las Cosas (IoT), la realidad aumentada, los vehículos autónomos y las ciudades inteligentes. Edge Computing se basa en dispositivos periféricos (edge devices) y nodos locales que realizan tareas de procesamiento y almacenamiento, lo que reduce la dependencia de la infraestructura centralizada de la nube.

### **Raspberry pi.**

Según Richardson y Wallace (2016), la Raspberry Pi es un dispositivo de computación de bajo costo y alto rendimiento que ha ganado popularidad en diversos campos debido a su versatilidad y facilidad de uso. Este dispositivo, del tamaño de una tarjeta de crédito, está equipado con un procesador ARM, memoria RAM, puertos de entrada/salida y conectividad de red, lo que lo hace una opción válida para proyectos educativos, de automatización y desarrollo de prototipos. La Raspberry Pi es capaz de ejecutar sistemas operativos basados en Linux, lo que permite a los usuarios programar y personalizar sus aplicaciones según sus necesidades (Richardson y Wallace, 2016).

Además, Upton y Halfacree (2020) destacan que la Raspberry Pi ha evolucionado significativamente

desde su lanzamiento, con modelos más potentes como la Raspberry Pi 4, que ofrece mayores capacidades de procesamiento, almacenamiento y conectividad. Este modelo incluye soporte para redes Gigabit Ethernet, puertos USB 3.0 y salidas de video de alta definición, lo que lo convierte en una herramienta poderosa para aplicaciones más exigentes, como servidores domésticos, centros multimedia y sistemas embebidos avanzados (Upton y Halfacree, 2020).

### **Python.**

Python es un lenguaje de programación poderoso, elegante y fácil de leer, diseñado para simplificar la creación de programas mediante una sintaxis clara y estructurada. Según el documento, Python destaca por su versatilidad en aplicaciones del mundo real, su enfoque en la legibilidad del código y su capacidad para integrar paradigmas como la programación orientada a objetos y funcional. Además, es software libre con una comunidad activa y una implementación estándar consolidada (Yuill y Halpin, 2006).

### **Tensorflow.**

Según Goldsborough (2016) TensorFlow es una biblioteca de software de deep learning de código abierto desarrollada por Google que permite definir, entrenar y desplegar modelos de machine learning mediante la representación de algoritmos como grafos computacionales.

La librería TensorFlow opera construyendo un grafo computacional en el que cada nodo representa una operación (por ejemplo, una función matemática, una transformación o una capa de una red neuronal) y cada arista transporta un tensor, es decir, un arreglo multidimensional de datos. Esta arquitectura facilita diversas mejoras de rendimiento, como la eliminación de subgrafos redundantes, y permite distribuir la ejecución de la computación a lo largo de múltiples dispositivos (CPUs, GPUs, TPUs) e incluso en entornos distribuidos. De esta manera, se reduce tanto el uso de memoria como el rendimiento, haciendo posible el entrenamiento y despliegue de modelos complejos a gran escala. (Goldsborough, 2016).

### **NestJs.**

Según Sabo (2020) NestJS es un framework para el desarrollo de aplicaciones del lado del servidor basado en Node.js, que se escribe en TypeScript. Proporciona una estructura modular y escalable mediante el uso de patrones modernos como la inyección de dependencias, controladores y

módulos, facilitando la creación de aplicaciones backend mantenibles y robustas.

NestJS aprovecha la solidez de Node.js y Express.js, pero se diferencia al introducir un enfoque inspirado en Angular para la organización de la aplicación. Gracias a su arquitectura basada en módulos, cada parte de la aplicación se encapsula en unidades independientes que facilitan la reutilización y la escalabilidad. Además, el framework implementa un avanzado sistema de inyección de dependencias, lo que permite gestionar y suministrar las instancias de servicios de manera automática, reduciendo el acoplamiento entre componentes y promoviendo un diseño orientado a pruebas. Otro pilar fundamental de NestJS es su fuerte integración con TypeScript, lo cual aporta tipificación estática y facilita la detección temprana de errores durante el desarrollo. La utilización de decoradores en NestJS permite agregar metadatos a clases, métodos y propiedades, lo que habilita la implementación de características como interceptores, pipes y controladores para la validación y transformación de datos, así como para el manejo de rutas HTTP. Además, la herramienta Nest CLI agiliza la generación de nuevos proyectos y componentes, garantizando que se siga una estructura coherente en toda la aplicación, lo que resulta especialmente útil en proyectos complejos y colaborativos (Sabo, 2020).

### **Inteligencia artificial.**

La Inteligencia Artificial (IA) se define como el estudio de agentes que perciben su entorno a través de sensores y actúan sobre él mediante actuadores, con el objetivo de maximizar su utilidad esperada. Según Russell y Norvig (2022), “La IA es el estudio de agentes que reciben percepciones del entorno y realizan acciones. Cada uno de estos agentes implementa una función que asigna secuencias de percepción a acciones, y cubrimos diferentes formas de representar estas funciones para lograr el mejor resultado esperado.” (p. 19).

Los fundamentos de la IA se entrelazan con múltiples disciplinas. La filosofía aporta marcos éticos y lógicos, como señalan los autores: “El filósofo griego Aristóteles fue uno de los primeros en intentar codificar el “pensamiento correcto” sus silogismos proporcionaron patrones para estructuras argumentales que siempre produjeron conclusiones correctas.” (p. 21). Las matemáticas y la estadística proporcionan herramientas para el razonamiento probabilístico: “La probabilidad rápidamente se convirtió en una parte invaluable de las ciencias cuantitativas, ayudando a lidiar con mediciones inciertas y teorías incompletas.” (p. 26). La economía contribuye con teorías de decisión y utilidad: “La teoría de la decisión, que combina la teoría de la probabilidad con la teoría de la utilidad, proporciona un marco formal y completo para las decisiones individuales tomadas en condiciones de incertidumbre.” (p. 28). La neurociencia y la psicología

inspiran modelos cognitivos: “El campo interdisciplinario de la ciencia cognitiva reúne modelos informáticos de la IA y técnicas experimentales de la psicología para construir teorías precisas y comprobables de la mente humana.” (p. 21). Por último, la ingeniería y la computación permiten implementar sistemas eficientes: “La historia de la IA es también la historia del diseño de arquitecturas cada vez más sofisticadas para programas de agentes.” (p. 65).

La IA actual ha alcanzado hitos significativos en diversos dominios. De acuerdo a los expuesto por Russell y Norvig (2022): “Los sistemas que usan IA han alcanzado o superado el rendimiento humano en ajedrez, Go, póquer, Pac-Man, Jeopardy, detección de objetos ImageNet, reconocimiento de voz y diagnóstico de retinopatía diabética.” (p. 46). En aplicaciones prácticas, destacan los vehículos autónomos: “Los vehículos de prueba de Waymo superaron la marca de 10 millones de millas recorridas en vías públicas sin sufrir accidentes graves.” (p. 47), y sistemas de diagnóstico médico: “Los algoritmos de IA ahora igualan o superan a los médicos expertos en el diagnóstico de muchas afecciones, como el cáncer metastásico y las enfermedades oftálmicas.” (p. 48). Además, herramientas como “Los sistemas de traducción automática ahora permiten la lectura de documentos en más de 100 idiomas, lo que genera cientos de miles de millones de palabras por día.” (p. 47) evidencian su impacto global. No obstante, persisten retos éticos y técnicos, como la alineación de valores humanos y la escalabilidad en entornos complejos, que definen la frontera actual de investigación.

### **Cadenas de Markov.**

Fundamentos teóricos Las Cadenas de Markov, nombradas en honor al matemático ruso Andrei Andreevich Markov (1856–1922), son procesos estocásticos que modelan sistemas donde el futuro depende únicamente del estado presente, sin influencia directa del pasado (Matas Soberón, 2024, p. 13). Este principio, conocido como propiedad de Markov, fue inicialmente aplicado por Markov en el análisis de secuencias de vocales y consonantes en textos literarios, como Eugene Onegin de Pushkin, sentando las bases para su uso en campos como la física, biología y ciencias sociales (Matas Soberón, 2024, p. 11). Posteriormente, estas cadenas han sido utilizadas para modelar sistemas en epidemiología, teoría de colas y dinámica de poblaciones (Bobadilla Osses, 2010, p. 5).

Una Cadena de Markov se define formalmente como un proceso estocástico  $X_n$  sobre un espacio de estados  $S$  (finito o numerable), donde la probabilidad de transición al siguiente estado depende exclusivamente del estado actual. Esta propiedad se traduce en una matriz de transición  $P = (p_{ij})$ , donde cada entrada  $p_{ij}$  representa la probabilidad de pasar del estado  $i$  al estado  $j$ . La matriz  $P$  es estocástica, es



decir, sus filas suman 1 y sus elementos son no negativos (Matas Soberón, 2024, p. 14-15). Además, en sistemas más avanzados, se pueden considerar Cadenas de Markov de tiempo continuo, las cuales presentan una relación con la teoría de semigrupos de operadores (Bobadilla Osses, 2010, p. 6).

Las cadenas de Markov pueden clasificarse en homogéneas, cuando la matriz de transición  $P$  permanece constante en el tiempo (Matas Soberón, 2024, p. 23). Un estado es recurrente si la cadena regresa a él infinitas veces, y transitorio si eventualmente lo abandona para siempre. Esto se determina mediante la representación canónica de  $P$ , que identifica clases cerradas (conjuntos de estados que no pueden abandonarse) (Matas Soberón, 2024, p. 24-25). En el contexto de sistemas biológicos, por ejemplo, una cadena de Markov puede utilizarse para modelar la propagación de una enfermedad dentro de una población, donde los estados pueden representar niveles de infección y la recurrencia indicar posibles rebrotes (Bobadilla Osses, 2010, p. 91).

Para cadenas regulares (matrices  $P$  con todas sus entradas positivas en alguna potencia), las probabilidades convergen a un estado estacionario  $w$ , único vector estocástico que satisface  $w = wP$ . Este resultado se fundamenta en el teorema de Perron-Frobenius y técnicas como la descomposición de Jordan (Matas Soberón, 2024, p. 29-30). Un caso particular de convergencia ocurre en modelos de colas, donde la distribución estacionaria describe la cantidad promedio de clientes en espera en el largo plazo (Bobadilla Osses, 2010, p. 84).

Los autores en sus respectivas publicaciones ilustran las utilidades de las Cadenas de Markov en casos reales. En fútbol, se utilizan para modelizar resultados (ganar, empatar, perder) en partidos de la liga española, calculando probabilidades de equilibrio para equipos ganadores y perdedores (Matas Soberón, 2024, p. 33-41). En póquer, se emplean para el análisis de rondas de apuestas y distribución de cartas, identificando estados recurrentes (como abandonar una partida) mediante matrices de transición (Matas Soberón, 2024, p. 42-48). En Google AdWords, se aplican para predecir el comportamiento de clics en anuncios, utilizando cadenas regulares para estrategias de marketing (Matas Soberón, 2024, p. 49-53). También se usan en el modelo de Reed-Frost en epidemiología para estudiar la propagación de enfermedades infecciosas, clasificando estados en susceptibles, infectados y recuperados (Bobadilla Osses, 2010, p. 91-107). Otro ejemplo es su aplicación en cadenas de colas, modelos de atención en sistemas de servicio como supermercados o sistemas de telecomunicaciones, donde la matriz de transición describe la dinámica de llegada y atención de clientes (Bobadilla Osses, 2010, p. 57-61).

## **Agente.**

Según Russell y Norvig (2022), un agente es cualquier entidad que percibe su entorno a través de sensores y actúa sobre él mediante actuadores. En este sentido, un agente puede ser un ser humano, un robot o un sistema de software, siempre que cumpla con esta función de percepción y acción. Por ejemplo, un agente humano posee sensores como los ojos y oídos, y actuadores como las manos y las piernas. Un agente robótico puede incluir cámaras y sensores infrarrojos como entrada, y motores como salida. Un software, en cambio, percibe datos en forma de archivos o paquetes de red y responde modificando archivos o enviando información a otros sistemas (Russell y Norvig, 2022).

El comportamiento de un agente está determinado por su función de agente, la cual define cómo actúa en función de la secuencia de percepciones que ha experimentado. En otras palabras, un agente toma decisiones basándose en su conocimiento previo y en los datos que recibe en tiempo real. Russell y Norvig (2022) también introducen el concepto de agente racional, que es aquel que elige acciones que maximizan su desempeño según un criterio predefinido. La complejidad del entorno en el que opera el agente influye directamente en su diseño y en su capacidad de tomar decisiones óptimas (Russell y Norvig, 2022).

## **Ciencia de datos.**

Según Provost y Fawcett (2013), la ciencia de datos se enfoca en el uso de datos para tomar decisiones informadas, utilizando herramientas como el aprendizaje automático, la minería de datos y el análisis estadístico. Los autores destacan que la ciencia de datos no solo se trata de manejar grandes volúmenes de datos, sino también de entender cómo estos pueden ser utilizados para generar valor en diferentes contextos, como en el ámbito empresarial, científico o social. Por su parte, Russell y Norvig (2022) enfatizan que la ciencia de datos es una disciplina que se apoya en la inteligencia artificial y el aprendizaje automático para modelar y predecir comportamientos a partir de datos. Los autores mencionan que la ciencia de datos es fundamental en la creación de sistemas inteligentes que pueden aprender de los datos y mejorar su desempeño con el tiempo. Además, resaltan la importancia de la ética en el manejo de datos, especialmente en aplicaciones que involucran la privacidad y la seguridad de las personas. García, Molina, y Berlanga (2018) complementan esta definición al señalar que la ciencia de datos es una disciplina que integra técnicas analíticas avanzadas, como el aprendizaje estadístico y la minería de datos, para resolver problemas complejos. Los autores destacan que la ciencia de datos no solo se limita al análisis de datos, sino que también incluye la preparación, limpieza y transformación de los datos para que

puedan ser utilizados en modelos predictivos y descriptivos. Además, resaltan la importancia de la visualización de datos como una herramienta clave para comunicar los resultados de manera efectiva.

En el contexto del Sistema de Monitoreo Acústico para Identificar Sonidos y Generar Alertas de Emergencia, la ciencia de datos juega un papel fundamental en varias etapas del proyecto. En primer lugar, se utiliza para el procesamiento y análisis de señales acústicas, donde se aplican técnicas de aprendizaje automático para clasificar sonidos ambientales y detectar eventos anómalos. Como mencionan Provost y Fawcett (2013), el aprendizaje automático es una herramienta poderosa para la clasificación de datos, especialmente en aplicaciones que requieren respuestas en tiempo real, como es el caso de este sistema.

Además, la ciencia de datos es esencial en la creación y entrenamiento de modelos predictivos que permiten identificar patrones de sonidos asociados a situaciones de emergencia. Russell y Norvig (2022) destacan que los modelos de inteligencia artificial, como las redes neuronales y las cadenas de Markov, son fundamentales para la predicción y clasificación de eventos basados en datos históricos. En este proyecto, se utilizan modelos preentrenados, como YAMNet, y se adaptan para la detección de sonidos específicos, lo que demuestra la aplicación práctica de la ciencia de datos en la creación de sistemas inteligentes. Por último, García y cols. (2018) resaltan la importancia de la visualización de datos en la comunicación de resultados. En este proyecto, la ciencia de datos no solo se limita al análisis de sonidos, sino que también incluye la generación de alertas visuales y notificaciones que permiten a los usuarios entender rápidamente la situación y tomar acciones adecuadas. Esto demuestra cómo la ciencia de datos puede ser utilizada para mejorar la usabilidad y efectividad de los sistemas de monitoreo.

### **Técnicas predictivas para series temporales.**

Según Hyndman y Athanasopoulos (2018), las series temporales son secuencias de datos ordenados en el tiempo, y su análisis implica la identificación de patrones como tendencias, estacionalidad y ciclos, para luego utilizarlos en la predicción de valores futuros. Las técnicas predictivas para series temporales son métodos estadísticos y de aprendizaje automático que permiten modelar y predecir el comportamiento futuro de datos que varían en el tiempo. Estas técnicas son fundamentales en aplicaciones donde es necesario anticipar tendencias, patrones o eventos futuros basados en datos históricos.

## **Transformers.**

Los Transformers son una arquitectura de red neuronal introducida por Vaswani y cols. (2017), cuyo principio central es el mecanismo de atención, que permite procesar secuencias en paralelo en lugar de manera secuencial, como ocurría en las redes recurrentes. Esto posibilita capturar dependencias de largo alcance en secuencias de datos, mejorando el rendimiento en tareas de procesamiento de lenguaje natural, visión y audio. La capacidad de atender de forma dinámica a distintas partes de la secuencia los hace más escalables, superando las limitaciones de las RNN y LSTM en problemas de dependencia a largo plazo. Actualmente, constituyen la base de modelos avanzados de IA como BERT y GPT, así como en aplicaciones emergentes de audio y monitoreo acústico

## **LSTM (Long Short-Term Memory).**

Las redes neuronales recurrentes (RNN) fueron diseñadas para procesar datos secuenciales, pero sufrían el problema del desvanecimiento del gradiente, lo que dificultaba capturar dependencias de largo plazo (Heaton, 2018). Para resolverlo, Hochreiter y Schmidhuber introdujeron las LSTM, que incorporan un mecanismo de memoria a través de una celda con tres puertas: de olvido, entrada y salida. Estas puertas permiten seleccionar qué información descartar, almacenar o transmitir, logrando que el modelo aprenda patrones de secuencia de manera más robusta.

Las redes neuronales recurrentes (RNN) fueron diseñadas para procesar datos secuenciales, pero se enfrentaban a un desafío importante: la incapacidad de retener información a largo plazo debido al problema del desvanecimiento del gradiente (Heaton, 2018). Para superar esta limitación crítica, Hochreiter y Schmidhuber (1997) desarrollaron las redes LSTM. Esta arquitectura innovadora no solo procesa secuencias de manera efectiva, sino que también introduce un mecanismo de memoria que le permite recordar información relevante por largos periodos, lo que era un obstáculo insalvable para las RNN tradicionales.

La capacidad distintiva de una red LSTM radica en su celda de memoria (cell state), que actúa como una cinta transportadora que lleva información relevante a lo largo de toda la secuencia de la red. A diferencia de una neurona simple, una celda LSTM está equipada con tres “puertas” reguladoras: la puerta de olvido (forget gate), la de entrada (input gate) y la de salida (output gate). Estas puertas, controladas por funciones sigmoideas, deciden qué información debe ser eliminada, qué información nueva debe ser agregada y qué información debe ser utilizada para generar la salida, respectivamente (Heaton, 2018).

La interacción entre estas puertas es lo que le da a las LSTM su poder. La puerta de olvido revisa el estado anterior y la entrada actual para determinar qué datos ya no son necesarios, limpiando la memoria. Luego, la puerta de entrada evalúa la nueva información y decide si es lo suficientemente importante para ser almacenada en la celda de memoria. Finalmente, la puerta de salida toma decisiones sobre la información contenida en la celda de memoria y la entrada actual para generar el valor de salida de la célula, permitiendo que la red utilice el conocimiento aprendido para una tarea específica (Heaton, 2018).

Gracias a este de control de memoria, las LSTM han demostrado ser efectivas en una amplia gama de aplicaciones. En el procesamiento del lenguaje natural (NLP), son fundamentales para la traducción automática y la generación de texto, ya que pueden capturar las dependencias gramaticales a largo plazo. También son cruciales en la detección de anomalías en secuencias de datos, como el audio, donde pueden aprender los patrones de sonido normales para luego identificar desviaciones que indican la presencia de una anomalía. Su éxito se debe a que superan la limitación de las RNN, permitiendo un mejor manejo de las dependencias a largo plazo (Hochreiter y Schmidhuber, 1997).

### **Autoencoders.**

Los autoencoders son redes neuronales no supervisadas diseñadas para aprender una representación comprimida de los datos de entrada (codificación) y luego reconstruirla (decodificación). Su objetivo es minimizar el error de reconstrucción, lo que permite capturar las características más importantes de los datos. En el caso del LSTM Autoencoder, se combinan las capacidades de los autoencoders con las LSTM, resultando especialmente útiles para datos secuenciales. Este tipo de modelo también sirve para simplificar los datos y encontrar patrones importantes, lo que ayuda a tareas como predecir valores futuros, comprimir información o mejorar otros modelos de aprendizaje (Malhotra, Vig, Shroff, Agarwal, y cols., 2015).

### **Isolation Forest (Bosque de Aislamiento).**

Isolation Forest es un método no supervisado de detección de anomalías que aísla observaciones mediante particiones aleatorias en bosques de árboles, donde las instancias atípicas requieren menos divisiones y, por tanto, muestran longitudes de camino esperadas más cortas. Su puntaje de anomalía deriva de la profundidad normalizada de aislamiento y no presupone distribuciones paramétricas ni datos etiquetados, lo que favorece su uso en flujos en línea y alta dimensionalidad (Aggarwal, 2016).

A diferencia de la mayoría de los algoritmos de detección de anomalías, que intentan construir un

perfil complejo de los datos “normales” para luego identificar lo que no encaja, Isolation Forest (IF) se basa en un principio mucho más directo. La premisa fundamental es que las anomalías son, por definición, “pocas y diferentes”, lo que las hace más susceptibles a ser aisladas que los puntos de datos normales (Liu, Ting, y Zhou, 2012).

El algoritmo funciona construyendo un conjunto de árboles de decisión aleatorios, conocidos como “árboles de aislamiento” (isolation trees). Para cada árbol, el conjunto de datos se particiona recursivamente seleccionando un atributo al azar y luego un valor de división aleatorio entre el valor máximo y mínimo de ese atributo. Este proceso de división aleatoria se repite hasta que cada punto de datos queda aislado en un nodo hoja del árbol. La idea central es que los puntos anómalos, al ser diferentes y estar más alejados de las concentraciones de datos normales, requerirán menos particiones para ser aislados (Liu y cols., 2012).

La “anomalía” de un punto se mide calculando la longitud del camino (path length) desde la raíz del árbol hasta el nodo hoja que lo contiene. Los puntos normales, que se encuentran en regiones densas, necesitarán muchos más cortes para ser aislados, resultando en caminos más largos. En contraste, las anomalías, que se encuentran en zonas de baja densidad, serán aisladas con muy pocos cortes, resultando en caminos muy cortos. El puntaje final de anomalía para cada punto se calcula promediando la longitud de su camino a través de todos los árboles del bosque, lo que hace que el resultado sea robusto y fiable (Liu y cols., 2012).

Gracias a su simplicidad y a no depender de cálculos de distancia o densidad, Isolation Forest es extremadamente rápido y tiene un bajo consumo de memoria. Estas características lo convierten en un candidato para la detección de anomalías en tiempo real sobre grandes volúmenes de datos, y es particularmente adecuado para ser implementado en dispositivos de borde (Edge) con recursos computacionales limitados, como es el caso de este proyecto.

### **Yamnet.**

Desarrollado por Google, YAMNet es un modelo preentrenado disponible en formato TFLite, lo que lo hace ideal para su implementación en sistemas embebidos o de bajo consumo computacional Google (s.f.). Este modelo fue descargado desde la plataforma Kaggle, en su página oficial. YAMNet está entrenado sobre el conjunto de datos AudioSet, que contiene más de 2 millones de segmentos de audio etiquetados con 521 clases de eventos sonoros, como gritos, ladridos, música, ruidos ambientales, entre otros Google (s.f.). AudioSet es un dataset a gran escala que busca proporcionar una cobertura integral de los sonidos

del mundo real Gemmeke y cols. (2017a). Esta amplia cobertura de clases convierte a YAMNet en una herramienta versátil para la detección de eventos críticos.

La arquitectura de YAMNet se basa en MobileNet v1, una red neuronal convolucional (CNN) diseñada específicamente para aplicaciones móviles y embebidas Google (s.f.). Esta arquitectura, que utiliza convoluciones separables en profundidad (depth-wise separable convolutions) para reducir la complejidad computacional Howard y cols. (2017), permite ejecutar el modelo en dispositivos con limitaciones de hardware sin sacrificar el rendimiento. El modelo acepta como entrada una forma de onda de audio en formato mono, muestreada a 16 kHz, y normalizada en el rango de  $[-1, 0, +1, 0]$ . Internamente, YAMNet divide la forma de onda en ventanas de 0.96 segundos con un salto (hop) de 0.48 segundos Google (s.f.), lo que permite analizar el audio en tiempo real. Cada ventana se procesa de manera independiente, generando tres tipos de salidas: scores, que contienen las puntuaciones de predicción para cada una de las 521 clases; y embeddings, que representan características de alto nivel extraídas del audio.

### **Redis Pub/Sub.**

Según Carlson (2013), Redis ofrece un sistema de publicación-suscripción (Pub/Sub) que permite a los clientes enviar mensajes a canales sin necesidad de conocer a los receptores. Esta arquitectura desacoplada es útil para sistemas distribuidos, notificaciones en tiempo real y flujos de eventos. Los clientes pueden suscribirse a uno o varios canales y recibir mensajes en tiempo real, sin almacenamiento ni persistencia. Carlson (2013) destaca que este mecanismo se caracteriza por su baja latencia y simplicidad: los mensajes no se almacenan, se entregan en mejor esfuerzo y se pierden si no hay suscriptores activos, lo que lo hace idóneo para eventos efímeros y señales transitorias.

### **Bases Legales**

El desarrollo del Sistema de Monitoreo Acústico se fundamenta en el cumplimiento de las normativas venezolanas vigentes relacionadas con la privacidad, protección de datos y seguridad informática. A continuación, se detallan los instrumentos legales aplicables:

#### **1. Constitución de la República Bolivariana de Venezuela (1999)**

- Artículo 60: Garantiza el derecho a la protección de la vida privada, intimidad, honor, propia imagen, confidencialidad y reputación.

- Artículo 28: Establece el derecho a la protección de datos personales.

## 2. Ley Especial contra Delitos Informáticos (2001)

- Artículo 6: Prohíbe el acceso no autorizado a sistemas informáticos.
- Artículo 20: Sanciona la violación de la privacidad mediante la interceptación de comunicaciones.

## 3. Ley Orgánica de Telecomunicaciones (2010)

- Artículo 3: Promueve el uso ético de las telecomunicaciones.

El proyecto prioriza la privacidad mediante:

- No almacenamiento de audios: Los sonidos capturados se procesan en tiempo real y se descartan inmediatamente después de su análisis.
- Base de datos local: La información técnica (como patrones de sonido y registros de alertas) se almacena en un servidor interno, sin conexión a internet, cumpliendo con el principio de confidencialidad.
- Transparencia: Los usuarios son informados sobre el funcionamiento del sistema y su finalidad, asegurando consentimiento informado conforme al artículo 60 constitucional.



### **Capítulo III. Marco Metodológico**

Este capítulo describe el conjunto de estrategias, técnicas y procedimientos empleados para el desarrollo del Sistema de Monitoreo Acústico para Identificar Sonidos y Generar Alertas de Emergencia. En él se detalla tanto el enfoque investigativo como las herramientas utilizadas para la recolección de datos y, fundamentalmente, la metodología de desarrollo adoptada, basada en el modelo espiral.

#### **Tipo de Investigación**

El presente trabajo constituye una investigación de tipo proyectiva. De acuerdo con Hurtado (2000), la investigación proyectiva tiene como objetivo diseñar o crear propuestas dirigidas a resolver determinadas situaciones. Los proyectos de arquitectura e ingeniería, el diseño de maquinarias, la creación de programas de intervención social, el diseño de programas de estudio, los inventos, la elaboración de programas informáticos, entre otros, siempre que estén sustentados en un proceso de investigación, son ejemplos de investigación proyectiva. Este tipo de investigación potencia el desarrollo tecnológico (p. 325).

Basado en esta definición, el desarrollo de un sistema de monitoreo acústico para identificar sonidos y generar alertas de emergencia se adapta a este tipo de investigación. El sistema propuesto en este trabajo se fundamenta en un proceso de investigación que incluye la revisión documental de conceptos como edge computing, el uso de modelos pre-entrenados para la clasificación de audio y el análisis de secuencias temporales para la detección de anomalías, así como el diseño e implementación de un prototipo funcional. Esto cumple con los requisitos de una investigación proyectiva, ya que no solo se analiza y diagnostica el problema, sino que también se desarrolla una solución tecnológica aplicable en entornos reales.

#### **Técnicas e Instrumentos de Recolección de Datos**

Según Hernández, Fernández, y Baptista (2014), las técnicas de recolección de datos son procedimientos sistemáticos que permiten obtener información relevante para la investigación, mientras que los instrumentos son las herramientas específicas utilizadas para registrar dicha información.

En este estudio, se emplearon técnicas tanto documentales como experimentales. La técnica

documental se utilizó para recopilar información teórica y antecedentes relacionados con los temas de la investigación. Para ello, se realizó una revisión bibliográfica de fuentes como artículos científicos, tesis y normativas legales, con el objetivo de construir el marco teórico que sustenta el proyecto. Esta técnica permitió fundamentar el diseño del sistema y justificar las decisiones técnicas adoptadas. Por otro lado, la técnica experimental se aplicó durante la fase de implementación y validación del sistema. Para ello, se diseñaron experimentos controlados en los que se capturaron y analizaron sonidos ambientales utilizando micrófonos y dispositivos Raspberry Pi. Los instrumentos utilizados en esta fase incluyeron software de procesamiento, así como protocolos de registro de datos para documentar los resultados de las pruebas. Como señala Tamayo (2004), “la recolección de datos debe ser precisa y sistemática para garantizar que la información obtenida sea válida y confiable” (p. 145). En este sentido, se implementaron protocolos estandarizados para la captura y clasificación de sonidos, asegurando que los datos fueran consistentes y representativos de los escenarios reales en los que se espera que opere el sistema.

### Metodología de Desarrollo Utilizada

Dado que al inicio del proyecto no se contaba con una definición completa de los requisitos, se necesitaba una metodología que fuera flexible y evolutiva. La elección del modelo de desarrollo se basó en la necesidad de gestionar activamente los riesgos técnicos, permitir una mejora continua a través de iteraciones y adaptar el sistema a los desafíos que surgieran durante la implementación.

Metodologías	Flexible	Evolutivo	Gestión de riesgos	Iteración y mejora continua
Espiral	Sí	Sí	Sí	Sí
Cascada	No	No	No	No
Incremental	No	Sí	No	Sí
Scrum	Sí	Sí	Si	Sí

Tabla 1: Cuadro Comparativo de metodologías

Esto implicaba ciclos de retroalimentación constantes, validación continua y refinamiento iterativo del sistema, características esenciales para alcanzar una solución en un contexto tan dinámico. La elección de una metodología de desarrollo adaptable permitió no solo enfrentar la incertidumbre técnica, sino también ajustar oportunamente el diseño según los aprendizajes obtenidos en cada etapa del proceso. Con esto en mente comparamos las distintas metodologías basándonos en esas necesidades en la Tabla 1.

Aunque metodologías ágiles como Scrum también cumplen con estos criterios, se optó por el modelo Espiral debido a su énfasis explícito en el 'Análisis de Riesgos' como una fase formal en cada ciclo. Dada la incertidumbre técnica del proyecto, esta característica fue considerada fundamental para mitigar de manera proactiva cualquier desafío técnico o de gestión que pudiera surgir.

Según lo propuesto por Boehm (1988), es un enfoque iterativo y flexible que combina elementos del desarrollo incremental y el prototipado, permitiendo gestionar riesgos y adaptar el sistema a medida que avanza el proyecto. Este modelo ha sido ampliamente reconocido por su capacidad para gestionar el desarrollo de sistemas complejos, ya que combina la naturaleza iterativa del prototipado con la estructura sistemática del modelo en cascada (Pressman, 2010, p. 39). En cada iteración, se pueden realizar ajustes en el plan del proyecto, permitiendo adaptar el software a las necesidades emergentes y reducir riesgos antes de que se conviertan en problemas críticos (Pressman, 2010, p. 40).

Según Boehm (1988), el Modelo Espiral se caracteriza por su estructura cíclica, en la que cada iteración incluye cuatro fases principales:

1. **Determinación de objetivos.** Inicialmente se definen los objetivos específicos de la iteración, identificando las limitaciones del proceso y del sistema de software. Se evalúan alternativas y se especifican condiciones como lenguaje, entornos, entre otros.
2. **Análisis de riesgos.** Se identifican y evalúan los riesgos potenciales. Se definen acciones para reducir los riesgos identificados y se evalúan alternativas existentes partiendo de prototipos, simulaciones y softwares de análisis. En este ciclo, existen varios prototipos como plantillas de diseño o componentes funcionales.
3. **Desarrollo.** Los prototipos se amplían y se añaden funcionalidades. El código es escrito, probado y migrado a un entorno de prueba varias veces hasta que pueda ser implementado correctamente.
4. **Planificación.** Al final de cada iteración se procede a planificar la siguiente, de ser necesaria. Si se producen errores, se buscan soluciones, y si se consiguen mejores alternativas, se implementa en el siguiente ciclo.

Como señala Boehm (1988), “el Modelo Espiral es particularmente adecuado para proyectos con altos niveles de incertidumbre y requisitos cambiantes, ya que permite incorporar retroalimentación continua y adaptar el diseño en función de los resultados obtenidos”. En este trabajo, esta metodología permitió

gestionar los riesgos técnicos y asegurar que el sistema cumpliera con los objetivos planteados. La Figura 1 ilustra el modelo de desarrollo en espiral propuesto por Boehm (1988).

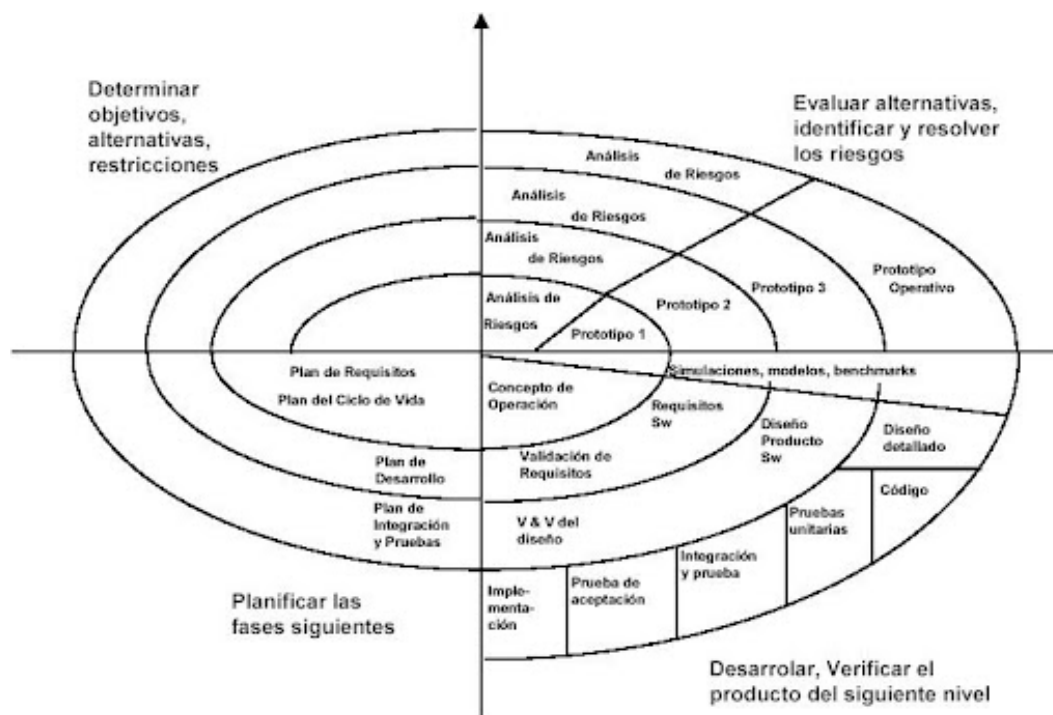


Figura 1: Modelo de desarrollo en espiral propuesto por Boehm (1988).

## **Capítulo IV. Desarrollo y Resultados**

En este capítulo se detalla el proceso de construcción del sistema de monitoreo acústico, siguiendo los ciclos de la metodología en espiral y su relación con los objetivos específicos. A continuación, se presentan las actividades y resultados obtenidos en cada iteración del proyecto.

### **Análisis inicial del sistema de monitoreo acústico para generar alertas en casos de emergencia.**

Desde el planteamiento del proyecto se identificó como un problema social relevante la detección de situaciones de emergencia en el hogar, especialmente para personas más expuestas a quedar desatendidas ante situaciones de vulnerabilidad, como adultos mayores que viven solos o personas con condiciones médicas que limitan su movilidad. Estudios como el de (Bezold, Krell-Roesch, Eckert, Jekauc, y Woll, 2021), destacan la prevalencia de caídas y emergencias médicas en estos grupos. Esta realidad evidencio la necesidad de un sistema de monitoreo que funcione de manera autónoma y discreta, sin depender de la intervención del usuario debido a su posible incapacidad para interactuar con un dispositivo durante una emergencia.

Para el análisis inicial del sistema, se comenzó con la revisión de literatura científica y técnica relacionada con la identificación y caracterización de eventos acústicos. Se prestó especial atención a estudios que abordaran la implementación de sistemas en dispositivos de Edge Computing.

Esta revisión incluyó estudios sobre el procesamiento de señales de audio y modelos de aprendizaje automático aplicados al reconocimiento de sonidos. Se encontró que era posible representar una señal de audio gráficamente como un espectrograma, que es una representación visual del sonido en función del tiempo y la frecuencia, donde la intensidad se codifica con color o brillo. Esto significa que la información necesaria para distinguir eventos sonoros, que se encuentra en las complejas estructuras de frecuencias del audio, podía ser interpretada mediante técnicas de análisis de imágenes.

Esto sugirió que, para una caracterización significativa del sonido, la estrategia de solución debía enfocarse en la Clasificación de Eventos Acústicos. En este contexto, la Inteligencia Artificial,

particularmente las Redes Neuronales Convolucionales (CNN), se presentó como el enfoque más adecuado para procesar y etiquetar la información compleja contenida en la estructura de frecuencias (el espectrograma). Este enfoque se ve respaldado por la literatura; por ejemplo, investigaciones en el diagnóstico de fallos de maquinaria han demostrado la efectividad de utilizar representaciones espectrales, como el Mel Spectrogram y el Scalogram, para la detección automática de anomalías acústicas mediante arquitecturas de Deep Learning (Tran y Lundgren, 2020).

Sabiendo que la clasificación de eventos acústicos conforma un componente necesario para la solución se identificó una limitante, la clasificación por sí sola no resolvía el problema, debido a la alta variabilidad del entorno sonoro domestico. No es lo mismo caracterizar sonidos en un entorno donde el comportamiento de las senales de audio es estable y predecible (como en una maquina), que en un hogar donde los sonidos son altamente dinámicos y contextuales. Es decir, la clasificación de eventos aislados no proporciona suficiente contexto para determinar si un evento es crítico o no. Por ejemplo, escuchar un grito sin contexto no permite determinar si es una situación de emergencia o una expresión normal de alegría o sorpresa. En otras palabras, la clasificación de eventos aislados es insuficiente para detectar situaciones críticas, ya que carece del contexto necesario para interpretar adecuadamente los eventos sonoros.

Ante esta limitante y asumiendo que las emergencias son eventos poco frecuentes y atípicos dentro del patrón de actividad sonora normal del hogar, se consideró la necesidad de analizar el comportamiento temporal de los eventos acústicos. Esto implicaba no solo clasificar los sonidos, sino también entender cómo estos eventos se distribuían a lo largo del tiempo para identificar patrones normales y detectar desviaciones significativas que pudieran indicar una emergencia.

Para abordar la necesidad del análisis de secuencias temporales, se revisaron estudios previos sobre predicción de eventos basados en series temporales. El uso de modelos predictivos como ARIMA, SARIMA o Prophet es una práctica establecida en la literatura para el desarrollo de sistemas de alerta temprana mediante el análisis y la predicción de patrones temporales Mora y Losada (2023). Estos modelos se perfilaban como una estrategia para establecer umbrales de predicción sobre la secuencia de eventos acústicos. El objetivo era determinar qué tan “típica” resultaba la ocurrencia en un momento dado, sirviendo así como un detector de patrones de comportamiento anómalo.

En función del analisis realizado, se procedio a definir los requerimientos del sistema de monitoreo acústico para la detección de emergencias en el hogar. La verificacion de los mismos se encuentra en la tabla

### **Requerimientos Funcionales.**

1. El sistema debe capturar el audio ambiental de forma continua a través de los micrófonos.
2. El sistema debe procesar el audio capturado para su caracterización.
3. El sistema debe caracterizar el perfil de la actividad acústica “típica” del entorno, basado en la estacionalidad de los eventos sonoros clasificados.
4. El sistema debe procesar y comparar la actividad sensada de manera inmediata con el perfil de normalidad para detectar patrones anómalos con la mínima latencia posible.
5. El sistema debe enviar notificaciones de emergencia a una lista de contactos predefinidos si se detecta una anomalía o grito de auxilio.

### **Requerimientos no funcionales.**

1. El sistema debe procesar y analizar los datos de audio en el borde (edge) sin almacenar las grabaciones de audio bruto ni información personal identificable.
2. El sistema debe ser capaz de integrar de manera flexible nuevos dispositivos de procesamiento (hardware) y/o de captura (micrófonos).
3. El sistema debe contar con una característica de inicio automático después de cualquier corte de energía o reinicio forzado.
4. El sistema debe tener un diseño modular que simplifique y agilice las tareas de mantenimiento y actualización de sus componentes.

## **Procedimiento Metodológico**

### **Primera Iteracion.**

El objetivo principal de la primera iteración fue validar la hipótesis de que se podían detectar anomalías en el comportamiento sonoro del entorno mediante el análisis de series temporales de intensidad. La estrategia consistió en utilizar un modelo estadístico para predecir el comportamiento sonoro “normal”, de modo que cualquier diferencia significativa entre el valor predicho y el valor real observado fuera




Figura 2: Prototipo basado en ESP32 y detección de intensidad de sonido

clasificada como una anomalía. El principal riesgo identificado en esta etapa fue la capacidad del modelo estadístico para funcionar adecuadamente en un entorno tan dinámico y variable como el doméstico.

Los componentes con los que contó esta iteración fueron un microcontrolador ESP32 y un micrófono que capturaba la intensidad de sonido. Véase en la figura 2. Esta serie temporal de niveles de intensidad sonora fue procesada por un modelo ARIMA (AutoRegressive Integrated Moving Average) para predecir el comportamiento esperado. Si la diferencia entre el valor predicho y el valor real superaba un umbral predefinido, se generaba una alerta.

El diseño del prototipo para probar este enfoque se inspiró en metodologías documentadas para sistemas IoT (Luis-García y Gómez, 2024) y consistió en un dispositivo de captura basado en un microcontrolador ESP32, que transmitía los datos a un servidor local (Raspberry Pi 4) para su análisis con el modelo ARIMA. Sin embargo, durante la fase de evaluación, este enfoque demostró ser fundamentalmente inviable. El problema de fondo no fue solo que el modelo ARIMA tuviera limitaciones funcionales, sino que su propio proceso de parametrización resultó ser incompatible con la naturaleza del problema de investigación.

La parametrización de ARIMA (basada en los parámetros  $p, d, q$ ) busca definir una estructura de dependencia y estacionalidad fija en los datos. En un entorno doméstico, la estacionalidad de los eventos acústicos es altamente variable y depende de múltiples factores contextuales, como la hora del día, el día de la semana, o eventos imprevistos. Esta variabilidad hace que sea extremadamente difícil definir parámetros fijos que puedan capturar adecuadamente los patrones normales de comportamiento sonoro para cualquier entorno, confirmando el riesgo inicial sobre la inestabilidad.

La principal limitación funcional de esta iteración fue la incapacidad de distinguir entre diferentes tipos de anomalías, ya que el modelo solo identificaba desviaciones en la intensidad del sonido sin considerar su naturaleza o contexto (e.g., una anomalía de volumen alto podía ser tanto una alarma como un evento



crítico).

Con estas limitaciones identificadas, se decidió avanzar hacia una segunda iteración que abordara estos desafíos.

### Segunda Iteracion.




Figura 3: Diseño de prototipo de esp32 con micrófono de señales de audio y prophet

En la Segunda Iteración, el objetivo fue superar la rigidez del modelo ARIMA, que resultó incompatible con la dinámica del entorno doméstico, manteniendo el enfoque de análisis de series temporales. La principal limitación, que se convirtió en el riesgo metodológico de esta etapa, radicaba en la pregunta de si la naturaleza dinámica y no estacionaria de los eventos domésticos podría ser modelada adecuadamente por cualquier librería de pronóstico que requiriera patrones estables. Se mantuvo la arquitectura de hardware de Edge Computing basada en el microcontrolador ESP32 y se aplicaron mejoras en la captura de datos. Se integraron micrófonos omnidireccionales INMP441 para asegurar una captura de señales acústicas de alta fidelidad, véase en la figura 3. A nivel de software, se reemplazó el modelo ARIMA por Prophet, una librería de pronóstico de series temporales desarrollada por Facebook, elegida por su capacidad para manejar estacionalidad y tendencias complejas, buscando mayor flexibilidad para modelar el entorno.

El modelo Prophet logró ajustarse eficazmente a las variaciones periódicas del sonido ambiental, como los patrones de ruido diurnos y nocturnos. Sin embargo, durante las pruebas se identificó una limitación crítica, confirmando el riesgo inicial asociado al pronóstico: el mecanismo interno del modelo para suavizar datos e identificar tendencias a largo plazo provocaba que se descartaran los eventos de corta duración y alta amplitud de interés. Sonidos instantáneos como un golpe, un grito o la rotura de un cristal

eran filtrados y no generaban alertas, ya que no formaban parte de un patrón estacional o de una tendencia predecible. Esta observación llevó a la conclusión definitiva de que el enfoque de pronóstico de series temporales, independientemente del modelo (ARIMA o Prophet), no era el adecuado para el objetivo del proyecto. El problema no era predecir la evolución del nivel de ruido, sino la detección de eventos atípicos e instantáneos basados en el contenido acústico. Por lo tanto, el problema se redefinió como uno de detección de anomalías en tiempo real basada en la caracterización de la señal. Para implementar esta nueva estrategia, se propuso un enfoque basado en una arquitectura de redes neuronales (Deep Learning).

La Planificación de la siguiente iteración se centró en la implementación de un modelo de clasificación acústica para caracterizar los eventos sonoros, seguido de un análisis temporal de las secuencias de eventos para detectar anomalías basadas en patrones de comportamiento.

### **Tercera iteración.**

El objetivo de esta tercera iteración fue abordar la necesidad de la caracterización semántica del sonido que se identificó como limitación crítica en las etapas previas. Inicialmente, la estrategia se centró en el desarrollo de un modelo de clasificación personalizado a partir de un conjunto de datos propio. El plan consistía en capturar y etiquetar una colección de sonidos de emergencia para entrenar una red neuronal diseñada específicamente para los escenarios de interés del proyecto. El principal riesgo metodológico de esta etapa fue la viabilidad de la adquisición de datos. Se asumió el riesgo de que la construcción de un dataset lo suficientemente vasto y diverso para garantizar la robustez y generalización del clasificador resultara inviable para los recursos del proyecto. A pesar de este riesgo, el diseño de hardware de Edge Computing se mantuvo para el desarrollo, enfocado en el procesamiento local de las señales.

Sin embargo, a medida que avanzaba el desarrollo, la investigación sobre la robustez de los clasificadores acústicos reveló la verdadera magnitud del desafío. Se hizo evidente que para que un modelo pudiera generalizar y operar de manera fiable, necesitaría ser entrenado con un volumen de datos masivo. La literatura académica confirma que la efectividad de los modelos de aprendizaje profundo para audio depende directamente de la escala y diversidad de los datos, requiriendo a menudo millones de ejemplos para capturar la enorme variabilidad de los sonidos del mundo real (Gemmeke y cols., 2017b). La tarea de construir un dataset de esa magnitud, confirmando el riesgo inicial, era logísticamente inviable para el proyecto.

Fue precisamente durante esta etapa de investigación que se identificó YAMNet, una arquitectura de

clasificación acústica ya pre-entrenada por Google. Este modelo fue entrenado sobre el corpus AudioSet, un extenso conjunto de datos que, como describen Gemmeke y cols. (2017b), contiene más de dos millones de clips de audio de 10 segundos etiquetados a partir de una ontología de 527 clases de eventos sonoros. El descubrimiento de YAMNet ofreció una solución directa al problema de la adquisición de datos a gran escala que se había identificado como el principal obstáculo. Ante esta situación, continuar con el desarrollo de un modelo propio habría significado un esfuerzo redundante. Por lo tanto, se tomó la decisión de descartar el enfoque personalizado y pivotar hacia la integración de YAMNet.

Esta medida representa una aplicación práctica del paradigma de aprendizaje por transferencia (transfer learning), que permite aprovechar el conocimiento de un modelo ya entrenado en un gran dataset para resolver un problema específico, tal como analizan Pons Puig y cols. (2019) en su trabajo sobre el impacto del tamaño del dataset en audio. Este pivote tecnológico permitió enfocar los recursos restantes del proyecto en la implementación del sistema final sobre una base tecnológica robusta y ya validada, y superar la limitación de la falta de contexto que afectó a las iteraciones basadas en series temporales.

#### Cuarta Iteración.




Figura 4: Prototipo con Raspberry Pi, Yamnet y Cadenas de Markov

En esta cuarta iteración del prototipo, se migró la lógica de procesamiento desde el ESP32 hacia una Raspberry Pi, con mayor capacidad computacional, véase en la figura 14. Se integraron micrófonos digitales de rango completo, capaces de capturar la señal de audio completa, lo que permitió acceder a un contenido espectral completo. Véase en la figura 4.

Con esta infraestructura, se incorporó YAMNet, un modelo de clasificación de audio en tiempo real basado en redes neuronales convolucionales entrenado con el dataset AudioSet de Google. YAMNet permite detectar y clasificar una gran variedad de eventos acústicos o (más de 500 categorías) como gritos, portazos, pasos, objetos cayendo, entre otros. Esta capacidad permitió dar un salto importante en la interpretación

contextual del entorno sonoro.

No obstante, Si bien YAMNet ofrecía una detección puntual efectiva de eventos sonoros, surgió la necesidad de dotar a dichos eventos de un significado secuencial y contextual. Para atender esta limitación, se optó por integrar un módulo de modelado probabilístico basado en cadenas de Márkov, con el fin de analizar la secuencia temporal de eventos y determinar si un patrón resultaba coherente con el comportamiento normal del entorno o, por el contrario, representaba una posible anomalía.

La decisión de emplear cadenas de Márkov estuvo fundamentada en dos aspectos principales: por un lado, en la existencia de estudios previos donde este tipo de modelos han sido utilizados para la detección de anomalías en secuencias temporales, destacando por su capacidad de representar probabilísticamente las transiciones entre estados inmediatos. En particular, investigaciones como la de Boldt, Borg, Ickin, y Gustafsson (2020), muestran cómo las cadenas de Márkov permiten identificar patrones irregulares en secuencias de eventos al modelar las transiciones esperadas y comparar estas con la realidad observada. Por otro lado, la elección también estuvo motivada por la recomendación del profesor de estadística Omar Castro, quien sugirió explorar este enfoque como un primer acercamiento al modelado secuencial de los eventos detectados.

No obstante, también surgieron limitaciones importantes. Si bien éramos capaces de detectar situaciones potencialmente peligrosas a partir de categorías específicas identificadas por YAMNet, el intento de modelar secuencias completas de eventos mediante cadenas de Márkov resultó ineficaz, ya que se quedaba saltando en ciclos infinitos de cambios de estado, por ejemplo (luego de Habla el siguiente evento mas probable era Habla). Estas cadenas se limitan a representar transiciones entre estados inmediatos, es decir, predicen solo el evento más probable siguiente, sin tener en cuenta el historial completo de eventos previos.

Intentar forzar el modelado de secuencias más largas con este enfoque llevó a comportamientos problemáticos, como ciclos repetitivos sin resolución lógica, o secuencias que carecían de coherencia contextual, especialmente cuando el espacio de eventos posibles crecía. Esta rigidez estructural impidió representar adecuadamente escenarios más complejos o ambiguos, donde la interpretación depende no solo del último evento detectado, sino de una serie de interacciones acústicas encadenadas en el tiempo.

Este hallazgo marcó un punto de inflexión en el desarrollo del sistema, motivando la exploración de enfoques más robustos y dinámicos, capaces de capturar dependencias de largo plazo en secuencias acústicas. En particular, se consideraron modelos como LSTM (Long Short-Term Memory) y transformers, que permiten aprender patrones secuenciales con memoria y contexto más amplio.

## Quinta Iteración.

En esta quinta iteración, nos enfocamos en el desarrollo de una solución más robusta para la detección de anomalías, como respuesta a las limitaciones encontradas con las cadenas de Markov. Para ello, basamos nuestro enfoque en el trabajo de Reis y Serôdio (2025), cuya investigación se centra en arquitecturas de Inteligencia Artificial en el borde (Edge AI) para el monitoreo en tiempo real. Específicamente, su estudio valida el uso de dos tecnologías que adoptamos: Isolation Forest (IF), un modelo para la detección de eventos anómalos basado en árboles, y un Long Short-Term Memory Autoencoder (LSTM), una red neuronal para el análisis de patrones secuenciales complejos.

Para la implementación de estos modelos en nuestro sistema, se replicaron las configuraciones de hiperparámetros validadas en dicho estudio para asegurar el rendimiento en la Raspberry Pi.

En el caso del Isolation Forest, adoptamos los hiperparámetros del estudio, configurando el modelo con 100 árboles ( $n_{estimators}$ ) y un parámetro de contaminación del 3 %. Este último valor asume una proporción esperada de anomalías en nuestros datos, alineándose con los escenarios simulados en la investigación de referencia, Véase en la figura 15

El segundo modelo implementado es un LSTM Autoencoder, una arquitectura de red neuronal no supervisada especialmente eficaz para la detección de anomalías en datos secuenciales (Malhotra y cols., 2015). Su objetivo es aprender una representación comprimida de los patrones “normales” presentes en los datos de entrenamiento para luego identificar desviaciones significativas. De igual manera, se adoptaron los hiperparámetros recomendados por Reis y Serôdio (2025), que incluyen un tamaño de lote de 32 y 50 épocas de entrenamiento. La arquitectura específica del modelo consta de 3 capas LSTM en el codificador y 3 capas LSTM en el decodificador, con tamaños de capa decrecientes de 32, 16 y 8 unidades respectivamente. y activación del ReLu para ajustar la tasa de aprendizaje y evitar el sobreajuste. Para el desarrollo y aplicación del modelo, se adoptó un enfoque metodológico inspirado en el trabajo de Reis y Serôdio (2025), el cual se estructuró en un proceso de tres etapas: preparación de los datos, construcción y entrenamiento de la arquitectura, y definición del mecanismo de detección.

1. Preparación de los Datos: Para que nuestro modelo LSTM pudiera interpretar los datos de los eventos, fue necesario “traducirlos” a un formato numérico que la red neuronal pudiera procesar. Este paso es crucial, ya que el modelo no entiende de fechas o etiquetas de texto por sí mismo; solo trabaja con números y mientras mas sentido y consistencia tengan esos números, mejor podrá aprender. Por ejemplo, si convertimos los días de la semana a números (domingo=0, lunes=1, ...,

sábado=6), el modelo interpretaría que el sábado (6) y el domingo (0) son valores muy distantes, cuando en realidad son adyacentes. Este tipo de malentendido impide que la red aprenda patrones que ocurren en la transición del fin de semana. Para resolver este problema, el enfoque consiste en representar las variables temporales de una manera que refleje su naturaleza cíclica. En lugar de ver el tiempo como una línea recta, lo tratamos como un círculo, similar a las manecillas de un reloj. Esto se logra mediante funciones matemáticas (seno y coseno) que asignan a cada instante una coordenada única en un círculo. De esta forma: El sábado queda matemáticamente “cerca” del domingo. Las 23:59 quedan justo al lado de las 00:00. Vease el Apendice A Este preprocesamiento es fundamental, pues permite que el modelo LSTM capture patrones de comportamiento continuos y lógicos, como los que ocurren durante la madrugada o en el cambio de un día para otro.

Convirtiendo Categorías en Señales Claras De manera similar, el modelo no puede procesar etiquetas de texto como “uso de microondas” o “sensor de movimiento”. Un error común sería asignarles un número a cada una (ej: microondas=1, sensor=2), ya que esto crearía una falsa relación matemática (como si el “sensor” fuera el doble del “microondas”). La solución es una técnica llamada One-Hot Encoding. Funciona como un panel de interruptores, donde cada evento posible tiene su propio interruptor. Cuando ocurre un evento, su interruptor se “enciende” (toma el valor de 1) mientras que todos los demás permanecen “apagados” (con valor de 0). De esta forma, el modelo recibe una señal clara y sin ambigüedades sobre qué evento específico sucedió, sin crear jerarquías o relaciones numéricas que no existen. Finalmente, el verdadero potencial de un modelo LSTM es su capacidad para entender el contexto. Un evento aislado, como “se enciende una luz”, no dice mucho. Pero si ocurre dentro de una “historia” o secuencia como “sensor de movimiento activado → se abre la puerta → se enciende la luz”, el patrón es mucho más revelador. Por esta razón, en lugar de analizar los eventos de forma individual, los agrupamos en secuencias superpuestas de una longitud fija (por ejemplo, 10 eventos consecutivos). Es como pasar de ver fotografías individuales a ver pequeños videoclips. Al entregarle los datos en este formato, el modelo LSTM no solo aprende “qué” pasó, sino “en qué orden” y “en relación con qué” otros eventos ocurrieron, permitiéndole así aprender los patrones complejos que definen un comportamiento normal. Con los datos ya “traducidos” a este formato numérico, cíclico y secuencial, el modelo está listo para comenzar su fase de entrenamiento.

2. Arquitectura del Modelo: Utilizamos un tipo especial de red neuronal llamado Autoencoder LSTM. La idea es bastante intuitiva. En lugar de predecir un valor futuro, el objetivo de un autoencoder es

aprender a reproducir su propia entrada. Podemos imaginarlo como intentar crear una figura circular con un lápiz y un compas, normalmente lo haríamos con el compas y el resultado es bastante predecible, pero al hacerlo a mano, el resultado va variar. Nuestro modelo funciona igual, se le entrena para ser un experto en reconstruir secuencias de eventos normales. Cuando se encuentra con una secuencia anómala, su reconstrucción es de mala calidad, y ese “error de reconstrucción” es la señal que nos alerta de una anomalía. La arquitectura del autoencoder se divide en dos partes simétricas: El Codificador (El Resumidor): Esta primera mitad de la red toma la secuencia de entrada (nuestro “videoclip” de 10 eventos) y la comprime progresivamente en una representación mucho más pequeña y densa. Es como si leyera un párrafo completo y lo resumiera en una sola idea clave. En nuestro caso, dos capas LSTM reducen la dimensionalidad de 32 a 16 bits, creando esa “idea” o resumen. El Decodificador (El Reconstructor): Esta segunda mitad toma la idea clave generada por el codificador y realiza el proceso inverso: intenta reconstruir la secuencia original de 10 eventos con la mayor fidelidad posible. Actúa como un espejo del codificador, expandiendo la representación de 16 de vuelta a 32 bits. Para mejorar la robustez del modelo y evitar que simplemente “memorice” los datos de entrenamiento, se incluyeron capas de Dropout. Estas capas “apagaban” aleatoriamente algunas neuronas durante el entrenamiento, forzando al modelo a aprender patrones más generales y significativos del comportamiento normal.

3. Entrenamiento y Detección: Una vez definida la arquitectura, el modelo entra en la fase de entrenamiento, que es donde aprende el comportamiento “normal”. El objetivo del entrenamiento es simple, hacer que el modelo sea bueno reconstruyendo las secuencias de eventos normales y muy malo haciendo lo mismo con las anómalas. Para ello, se le alimenta con una serie constante de datos que representan la normalidad. El modelo procesa los datos en un ciclo de “ensayo y error” intentando reconstruir una secuencia normal, luego compara la secuencia original con su reconstrucción y calcula el “error de reconstrucción” (qué tan diferente es su copia del original), usando una métrica llamada Error Cuadrático Medio (MSE). Luego Ajusta sus parámetros internos para reducir ese error en el siguiente intento, este proceso se repite miles de veces para hacer al modelo más inteligente, durante este proceso se utilizan dos mecanismos de supervisión para evitar que el modelo se sobreentrene o se estanque:

- a) EarlyStopping (Parada Temprana): Es un supervisor que detiene el entrenamiento automáticamente si el modelo deja de mejorar. Esto evita el sobreajuste (que el modelo “memorice” en lugar de “aprender”) y ahorra tiempo de cómputo.

- b) ReduceLROnPlateau (Reducción de Tasa de Aprendizaje): Si el modelo se estanca, este mecanismo reduce la magnitud de los ajustes que realiza, permitiéndole un aprendizaje más fino y preciso para superar el estancamiento.

Luego de que el modelo ha sido entrenado y puede reconstruir consistentemente las secuencias normales con bajo error, está listo para la fase de detección de anomalías. Para ello, calculamos nuestro umbral de decisión basado en la distribución estadística de los errores de reconstrucción obtenidos durante el entrenamiento. Este umbral define el límite entre lo que consideramos un comportamiento normal y una posible anomalía. Este umbral se establece en el percentil 99.95 de los errores de reconstrucción en los datos normales, lo que significa que solo el 0.05 % de las secuencias normales tendrán un error mayor que este valor. Cualquier secuencia que el modelo intente reconstruir y que produzca un error de reconstrucción superior a este umbral será clasificada como una anomalía. Este enfoque estadístico asegura que el modelo sea sensible a desviaciones significativas del comportamiento aprendido, es necesario para reducir las falsas alarmas y garantizar que solo los eventos verdaderamente atípicos sean señalados para una revisión más detallada.

### ***Evaluacion de los Modelos.***

En esta etapa de evaluacion, nos centramos por completo en el desempeño de detección del modelo. El propósito es analizar qué tan bien la arquitectura puede distinguir entre patrones normales y anómalos. Para ello, se utilizó un conjunto de datos de prueba independiente, que incluye tanto secuencias normales como una serie de anomalías introducidas artificialmente para simular eventos críticos. Este conjunto no fue utilizado durante el entrenamiento, asegurando así una evaluación objetiva del modelo.

### ***Evaluacion del LSTM Autoencoder.***

Para evaluar el rendimiento del modelo, se empleó un conjunto de datos de prueba, el cual es una porción de los datos que el modelo no observó durante su entrenamiento. Este conjunto contenía tanto secuencias de comportamiento normal como una serie de anomalías que fueron introducidas artificialmente en el dataset para simular eventos atípicos. El proceso consistió en pasar cada una de las 45,841 secuencias de prueba a través del autoencoder ya entrenado y calcular su error de reconstrucción (MSE). Posteriormente, este error fue comparado con un umbral de anomalía definido estadísticamente a partir de la distribución de errores del conjunto de entrenamiento (específicamente, el percentil 99.95). Cualquier secuencia cuyo error



de reconstrucción superara este umbral fue clasificada como una anomalía.

La selección de este percentil (99.95) no fue un valor arbitrario. Para definir el umbral de decisión, se realizó un análisis de la Curva ROC (Receiver Operating Characteristic). Esta herramienta permite evaluar el balance entre la capacidad de detectar anomalías reales (Tasa de Verdaderos Positivos) y la tasa de falsas alarmas (Tasa de Falsos Positivos) para diferentes umbrales. Se probaron varios percentiles y se seleccionó aquel que maximizaba el Área Bajo la Curva (AUC), una métrica que resume la capacidad global del modelo para distinguir entre clases. Como se muestra en la gráfica, el umbral del 99.95 % permitió alcanzar un AUC de 0.79, un valor cercano al objetivo de 0.8, lo que confirma que el umbral elegido posiciona al modelo en un punto de operación con un sólido equilibrio entre sensibilidad y especificidad.




Figura 5: Curva ROC y AUC del LSTM Autoencoder

El resultado principal del proceso de validación se puede observar directamente en el siguiente gráfico, que muestra el momento exacto en que el modelo detecta una anomalía.

En la gráfica de la figura 6, se visualiza el error de reconstrucción para cada secuencia del conjunto de prueba. La línea discontinua roja representa el umbral de anomalía ( $MSE = 0.001646$ ). Los puntos rojos marcan las 21 secuencias cuyo error superó este límite, siendo clasificadas correctamente como anomalías. Este gráfico confirma visualmente que el modelo es efectivo para asignar una puntuación de error mucho más alta a los eventos que se desvían del comportamiento normal aprendido.

Para analizar en detalle el rendimiento del modelo, no es suficiente con saber el número total de




Figura 6: Gráficas de MSE por secuencia para el LSTM Autoencoder.

anomalías detectadas. Es fundamental comprender la naturaleza de sus aciertos y errores, y para ello se utiliza la matriz de confusión. Esta herramienta es una tabla que desglosa los resultados al comparar las predicciones del modelo con la realidad del conjunto de prueba, permitiéndonos visualizar cuatro escenarios clave:

- Verdaderos Positivos (VP): Las anomalías que el modelo identificó correctamente.
- Verdaderos Negativos (VN): Los eventos normales que el modelo clasificó correctamente como normales.
- Falsos Positivos (FP): Eventos normales que el modelo etiquetó erróneamente como anomalías (las “falsas alarmas”).
- Falsos Negativos (FN): Las anomalías reales que el modelo no fue capaz de detectar (los errores más críticos).

VP (Verdaderos Positivos): 18

FP (Falsos Positivos): 3

FN (Falsos Negativos): 6

VN (Verdaderos Negativos): 45814

Estas cifras se traducen en las siguientes métricas de rendimiento:

Esperado		
Real	P	N
V	18	6
F	3	45814

Tabla 2: Matriz de Confusión del LSTM Autoencoder

- Exactitud (Accuracy): proporción de predicciones correctas respecto al total de casos evaluados.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} = \frac{(18 + 45814)}{(18 + 45814 + 3 + 6)} \approx 0,9998 \quad (1)$$

- Tasa de error: proporción de predicciones incorrectas respecto al total.

$$Error = \frac{FP + FN}{TP + TN + FP + FN} = \frac{(3 + 6)}{(18 + 45814 + 3 + 6)} \approx 0,0002 \quad (2)$$

- Sensibilidad (Recall o Verdaderos Positivos): proporción de eventos de anomalos correctamente detectados.

$$Recall = \frac{TP}{TP + FN} \quad (3)$$

- Precisión: La proporción de casos realmente positivos entre todos los casos que el modelo predijo

como positivos.

$$Precision = \frac{TP}{TP + FP} = \frac{18}{18 + 3} \approx 0,8571 \quad (4)$$

- Especificidad: proporción de eventos no críticos correctamente descartados.

$$Specificity = \frac{TN}{TN + FP} = \frac{45814}{45814 + 3} \approx 0,9999 \quad (5)$$

- F1 Score: media armónica entre la precisión y la sensibilidad, útil cuando es importante equilibrar ambas.

$$F1_{score} = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} = 2 \cdot \frac{0,8571 \cdot 0,75}{0,8571 + 0,75} \approx 0,8 \quad (6)$$

El análisis de las métricas de rendimiento cuantifica el desempeño del modelo. La exactitud general es del 99.98 %, aunque este valor es menos indicativo en conjuntos de datos con clases desbalanceadas. Un análisis más específico muestra una Sensibilidad (Recall) del 75.0 %, lo que indica que el modelo identifica a tres de cada cuatro anomalías reales. A su vez, la Precisión es del 85.7 %, lo que significa que sus alertas positivas son correctas en esa proporción. La puntuación F1, como media armónica de ambas, se sitúa en 80.0 %, reflejando el balance entre la capacidad de detección y la fiabilidad de sus predicciones.

Por último, la curva ROC (figura 5) y su AUC de 0.792 confirman que el modelo tiene una buena capacidad para distinguir entre comportamientos normales y anómalos, situándose cerca del umbral deseado

de 0.8. En conjunto, estos resultados validan la efectividad del LSTM Autoencoder para la detección de anomalías en secuencias de eventos en nuestro contexto específico.

### *Evaluación del Isolation Forest.*

Para la evaluación del modelo Isolation Forest (IF), una técnica no supervisada que opera de manera fundamentalmente distinta al autoencoder. En lugar de medir un error de reconstrucción, este modelo asigna una “puntuación de anomalía” a cada evento basándose en qué tan fácil es aislarlo del resto de los datos. Los eventos que son más fáciles de separar (requieren menos divisiones en los árboles de decisión) se consideran más anómalos.

Funciona construyendo múltiples árboles de decisión (en este caso, 100) estos árboles se construyen al dividir aleatoriamente los datos en subconjuntos. Funciona bajo la premisa de que las anomalías son puntos de datos que se encuentran en regiones menos densas del espacio de características, por lo que son más fáciles de aislar. Cada evento recibe una puntuación basada en la profundidad promedio a la que aparece en los árboles; cuanto más cerca esté la puntuación de 1, más anómalo es el evento.

El proceso de evaluación se aplicó sobre el mismo conjunto de datos, compuesto por 100,809 registros, de los cuales 5,041 (5 %) son anomalías reales. A diferencia del LSTM Autoencoder, el umbral de decisión en el Isolation Forest no se calcula estadísticamente a posteriori, sino que se define a priori mediante el hiperparámetro contamination. Este valor se estableció en 0.05 (5 %), una práctica estándar para configurar este algoritmo. Cualquier evento cuya puntuación de anomalía superara el umbral derivado de esta configuración fue clasificado como anómalo.

- **Análisis de la Detección**

El análisis de los resultados del Isolation Forest revela un rendimiento significativamente inferior al del LSTM Autoencoder. El modelo identificó un total de 5,041 eventos como anómalos. Sin embargo, un desglose más profundo a través de la matriz de confusión es necesario para entender la verdadera efectividad de estas detecciones.

Para analizar en detalle el rendimiento del modelo, se utiliza la matriz de confusión. Esta herramienta desglosa los resultados al comparar las predicciones del modelo con la realidad del conjunto de prueba, permitiéndonos visualizar cuatro escenarios clave:

VP (Verdaderos Positivos): 2,877




Figura 7: Gráficas de puntuación de anomalía por evento para el Isolation Forest.

Esperado		
Real	P	N
V	2877	8031
F	2164	87737

Tabla 3: Matriz de Confusión del Isolation Forest

FP (Falsos Positivos): 2,164

FN (Falsos Negativos): 8,031

VN (Verdaderos Negativos): 87,737

- Métricas de Rendimiento

$$Accuracy = \frac{(2877 + 87737)}{(2877 + 87737 + 2164 + 8031)} \approx 0,8989$$

(7)

$$Error = \frac{(2164 + 8031)}{(2877 + 87737 + 2164 + 8031)} \approx 0,101$$

(8)

$$Recall = \frac{2877}{2877 + 8031} \approx 0,2638$$

(9)

$$Precision = \frac{2877}{2877 + 2164} \approx 0,5707$$

(10)

$$Specificity = \frac{87737}{87737 + 2164} \approx 0,9759$$

(11)

$$F1_{score} = 2 \cdot \frac{Precision * Recall}{Precision + Recall}$$

(12)

El análisis de las métricas de rendimiento cuantifica el desempeño del modelo. La exactitud general




Figura 8: Curva ROC y AUC del Isolation Forest.

del 89.9% es un valor engañoso, inflado por la gran cantidad de eventos normales correctamente identificados. Las métricas más importantes revelan un rendimiento bajo: una Sensibilidad (Recall) de solo el 26.4 %, lo que indica que el modelo no detectó a más de 3 de cada 4 anomalías reales. A su vez, la Precisión es del 57.1 %, lo que significa que casi la mitad de sus alertas son falsas alarmas. La puntuación F1 resultante, del 36.1 %, confirma que el modelo, en su configuración actual, carece de la capacidad necesaria para una detección fiable de anomalías en este contexto.

La curva ROC (figura 8) y su AUC de 0.612 refuerzan esta conclusión, situando al modelo muy por debajo del umbral deseado de 0.8. En conjunto, estos resultados indican que el Isolation Forest, con los hiperparámetros adoptados, no es adecuado para la detección de anomalías en secuencias de eventos en nuestro contexto específico.


En la figura 7, se visualiza la puntuación de anomalía asignada por el modelo a cada evento del conjunto de prueba. Los puntos rojos marcan los eventos cuya puntuación superó este límite, siendo clasificados como anomalías. Este gráfico ilustra cómo el modelo asigna puntuaciones más altas a ciertos eventos, pero la distribución de estas puntuaciones no es lo suficientemente clara como para distinguir entre comportamientos normales y anómalos.



## Sexta Iteración.

En esta sexta iteración, luego de evaluar los resultados obtenidos con ambos modelos, se decidió adoptar el LSTM Autoencoder como solución principal para la detección de anomalías en el sistema de monitoreo acústico. Esta elección se fundamentó en su desempeño superior durante la fase de evaluación, donde superó significativamente al modelo Isolation Forest en todas las métricas clave.

Sin embargo, se identificó un riesgo técnico relevante: los hiperparámetros del LSTM Autoencoder fueron adoptados directamente del estudio de Reis y Serôdio (2025), sin una adaptación específica para nuestro conjunto de datos. Esto implica que, aunque el modelo mostró un rendimiento sólido, existe la posibilidad de que ajustes finos en estos parámetros puedan mejorar aún más su eficacia en nuestro contexto particular.



```

CONFIG = {
    'seq_len': 10,                # Longitud de la secuencia de entrada (lookback). Aumentado para más contexto.
    'lstm_units': 32,            # Número de neuronas/unidades en la capa LSTM.
    'dropout_rate': 0.2,         # Tasa de desactivación (regularización).
    'percentile_threshold': 99.95, # Umbral para filtrar valores atípicos (outliers).
    'test_size': 0.2,            # Proporción para el conjunto de prueba.
    'random_state': 42,          # Semilla de aleatoriedad (reproducibilidad).
    'epochs': 50,                # Máximo número de épocas de entrenamiento.
    'batch_size': 32,            # Tamaño del lote de entrenamiento.
    'patience': 10,             # Épocas de espera para Early Stopping. Más paciencia.
    'use_temporal_split': False  # Booleano para usar división temporal de datos. Cambiar a True.
}

```

Figura 9: Parametros originales.

Estos parametros se visualizan en la figura 9.

Reconociendo esta limitación, se revisaron estudios sobre optimización de hiperparámetros, lo que derivó en la implementación de un proceso basado en optimización bayesiana. Esta técnica permitió mejorar los resultados obtenidos inicialmente, al encontrar mejores configuraciones más con menos evaluaciones del modelo.

La optimización bayesiana, como se describe en el trabajo de Gardner y cols. (2014), utiliza modelos probabilísticos (usualmente procesos gaussianos) para estimar el comportamiento de la función objetivo y seleccionar los puntos de evaluación mediante funciones de adquisición que balancean exploración y explotación. Este enfoque es especialmente útil cuando tanto la función objetivo como las restricciones son costosas de evaluar, como ocurre en nuestro sistema de monitoreo acústico.

Luego de aplicar este proceso de optimización, se obtuvieron nuevos valores para los hiperparámetros del LSTM Autoencoder, los cuales se detallan a continuación:

```

CONFIG = {
    'seq_len': 5,                # Longitud de la secuencia de entrada (lookback)
    'lstm_units': 119,           # Número de neuronas/unidades LSTM
    'dropout_rate': 0.1000,      # Tasa de desactivación (regularización)
    'percentile_threshold': 99.9500, # Umbral para filtrar valores atípicos (outliers)
    'test_size': 0.2000,         # Proporción para el conjunto de prueba
    'random_state': 42,          # Semilla de aleatoriedad (reproducibilidad)
    'epochs': 100,               # Máximo número de épocas de entrenamiento
    'batch_size': 22,            # Tamaño del lote de entrenamiento
    'patience': 15,             # Épocas de espera para Early Stopping
    'use_temporal_split': False, # Indica si la división de datos es temporal o aleatoria
}

```

Figura 10: Parametros nuevos.

### *Evaluacion del LSTM Autoencoder V2.*

Para evaluar el rendimiento del modelo V2, se empleó el mismo conjunto de datos de prueba utilizado anteriormente, asegurando así una comparación directa y objetiva. Este conjunto contenía tanto secuencias de comportamiento normal como una serie de anomalías introducidas artificialmente para simular eventos atípicos. El proceso de evaluacion fue idéntico al aplicado previamente, pasando cada una de las 45,841 secuencias de prueba a través del autoencoder V2 y calculando su error de reconstrucción (MSE). Posteriormente, este error fue comparado con un umbral de anomalía redefinido tras la optimización bayesiana. Cualquier secuencia cuyo error de reconstrucción superara este nuevo umbral fue clasificada como una anomalía.




Figura 11: Curva ROC y AUC del LSTM Autoencoder V2.




Figura 12: Gráficas de MSE por secuencia para el LSTM Autoencoder V2.

En la gráfica de la figura 12, se visualiza el error de reconstrucción para cada secuencia del conjunto de prueba tras la optimización. La línea discontinua roja representa el nuevo umbral de anomalía. Los puntos rojos marcan las secuencias cuyo error superó este límite, siendo clasificadas correctamente como anomalías. Este gráfico confirma visualmente que el modelo optimizado es aún más efectivo para asignar una puntuación de error alta a los eventos que se desvían del comportamiento normal aprendido.

Esperado		
Real	P	N
V	19	0
F	2	45820

Tabla 4: Matriz de Confusión del LSTM Autoencoder V2

VP (Verdaderos Positivos): 19 FP (Falsos Positivos): 2 FN (Falsos Negativos): 0 VN (Verdaderos Negativos): 45820 Estas cifras se traducen en las siguientes métricas de rendimiento:

- Exactitud (Accuracy):

$$Accuracy = \frac{(19 + 45820)}{(19 + 45820 + 2 + 0)} \approx 0,9999$$

(13)

- Tasa de error (Error Rate):

$$Error\ Rate = \frac{(2 + 0)}{(19 + 45820 + 2 + 0)} \approx 0,00004 \quad (14)$$

- Sensibilidad (Recall):

$$Recall = \frac{19}{19 + 0} \approx 1,0000 \quad (15)$$

- Precisión (Precision):

$$Precision = \frac{19}{19 + 2} \approx 0,9048 \quad (16)$$

- Especificidad (Specificity):

$$Specificity = \frac{45820}{45820 + 2} \approx 0,9999 \quad (17)$$

El análisis de las métricas de rendimiento cuantifica el desempeño del modelo V2. La exactitud general es del 99.98 %, similar al modelo previo, pero con mejoras notables en las métricas clave. La Sensibilidad (Recall) es del 100 %, indicando que el modelo ahora detecta todas las anomalías reales, un avance significativo. La Precisión ha aumentado a 90.48 %, lo que significa que casi todas sus alertas positivas son correctas. La puntuación F1 refleja este equilibrio mejorado, situándose en un valor más alto que antes, lo que confirma que los nuevos parametros han mejorado la capacidad del modelo para detectar

anomalías de manera fiable y a reducir las falsas alarmas.

La curva ROC (figura 11) y su AUC de 1.0 confirman que el modelo optimizado tiene una capacidad excelente para distinguir entre comportamientos normales y anómalos, superando ampliamente el umbral deseado de 0.8. En conjunto, estos resultados validan la efectividad del LSTM Autoencoder V2 para la detección de anomalías en secuencias de eventos en nuestro contexto específico.

La figura 12 ilustra la mejora en la distribución de errores de reconstrucción tras la optimización. La reducción en el número de falsas alarmas y la eliminación de falsos negativos destacan la eficacia del proceso de optimización bayesiana en la mejora del rendimiento del modelo.

### **Diseño final de la arquitectura del sistema.**

Con base en los resultados obtenidos durante las fases de desarrollo y evaluación, se procedió a diseñar el sistema final de monitoreo acústico para la detección de anomalías y generación de alertas en casos de emergencia. Este diseño integra tanto el hardware como el software necesarios para su implementación efectiva.

La arquitectura implementada se fundamenta en el modelo en capas, donde cada nivel cumple funciones específicas alineadas con los requisitos funcionales y no funcionales del sistema. La Capa de Captación de Audio (Micrófonos, Raspberry Pi) satisface el RF1 al garantizar la captura continua de audio; la Capa de Clasificación de Audio (Vosk, Yamnet, Activity-Agent) cumple el RF2 y parcialmente el RF4 al procesar y caracterizar la señal; la Capa de Detección de Anomalías (LSTM, IF-Agent) y la Capa de Gestión de Alertas (Emergency-Agent) abordan el núcleo del problema, cumpliendo el RF4 al detectar patrones anómalos; la Capa de Gestión de Datos (Postgres, Redis) facilita el RF3 al almacenar la información necesaria para caracterizar la actividad acústica "típica"; y la Capa de Notificaciones (Telegram, SMTP) garantiza el cumplimiento del RF5 al enviar alertas validadas. Estas capas no se ejecutan como módulos monolíticos, sino como procesos independientes que se comunican mediante un esquema pub/sub interno con Redis, lo que introduce un componente distribuido local. Esta modularidad no solo simplifica el mantenimiento y la actualización de componentes (RNF4), sino que también facilita la integración flexible de nuevos agentes o dispositivos (RNF2), ya que solo necesitan publicar o suscribirse a canales de Redis para interactuar. Además, el uso de un Raspberry Pi como nodo principal aproxima la solución al concepto de servidores al borde (edge computing), lo cual es esencial para cumplir el RNF1: el procesamiento y análisis de datos de audio ocurre localmente, minimizando la latencia (clave para el RF4).

y evitando el almacenamiento de grabaciones de audio bruto o información personal identificable. Esta combinación de estilo cliente-servidor con mecanismos de colaboración descentralizados, según Tanenbaum y Van Steen (2007), se entiende como una arquitectura híbrida. Por último, la naturaleza embedded del sistema sobre el Raspberry Pi permite la configuración de inicio automático a nivel de sistema operativo (RNF3), asegurando la continuidad del monitoreo tras fallos o reinicios. De esta manera, la propuesta logra unir la claridad del enfoque en capas con la flexibilidad de un sistema distribuido basado en microservicios locales, satisfaciendo los requisitos funcionales y no funcionales.

Los algoritmos de los distintos agentes se encuentran en el apéndice D



Figura 13: Arquitectura del sistema de monitoreo acústico para generar alertas en casos de emergencia

1. Capa de captación de audio: Esta capa corresponde al nivel más cercano al hardware y tiene como función principal la adquisición de datos acústicos mediante los micrófonos conectados al dispositivo Raspberry Pi. Se encarga de gestionar la interacción con el sistema operativo para acceder a las señales de audio en tiempo real y ponerlas a disposición del sistema a través de canales de comunicación internos. Su objetivo es abstraer la complejidad del hardware y garantizar que los datos se entreguen de forma continua a las capas superiores.

2. Capa de clasificación de audio: Se encarga de analizar las señales acústicas recibidas de la capa de captación, tomando el flujo de audio en bruto como entrada para su procesamiento inmediato. En este nivel, múltiples agentes especializados (como Yamnet-Agent) procesan el flujo de audio con el fin de determinar la presencia de actividad, reconocer palabras clave y clasificar eventos característicos (como golpes, vidrios rotos o gritos) directamente a través de modelos preentrenados. Los resultados de este procesamiento se estructuran en mensajes que representan descripciones semánticas de la señal (es decir, una representación del sonido en términos de significado o evento), reduciendo drásticamente el volumen de datos y facilitando la interpretación, que se entiende como la traducción de datos brutos a eventos categorizados y listos para el análisis en etapas posteriores.
3. Capa de detección de anomalías: En esta capa se aplican modelos de aprendizaje automático cuyos parámetros han sido fijados mediante un entrenamiento offline (como Isolation Forest y LSTM), pero que se ejecutan en tiempo real para la detección de anomalías. Utilizando los datos clasificados por la capa anterior como entrada, el sistema evalúa el comportamiento acústico observado de manera inmediata (online), diferenciando si este corresponde a patrones esperados o si representa una desviación significativa, como se demuestra con el cálculo del Mean Squared Error (MSE) en el LSTM-Agent. Esta capa constituye el núcleo analítico del sistema, ya que transforma datos objetivos en juicios de normalidad o anomalía en el momento en que ocurren. Si bien la detección de la anomalía es el objetivo principal de este nivel, el resultado debe ser complementado y validado por la Capa de Gestión de Alertas para añadir el componente contextual y la toma de decisión final.
4. Capa de gestión de alertas: La función de esta capa es servir como el punto de decisión central del sistema, determinando cuáles de las anomalías detectadas deben ser escaladas como alertas finales al usuario. Si bien la implementación actual trata casi toda anomalía detectada por los agentes (Yamnet, LSTM, etc.) como una alerta inmediata, el diseño de la capa está basado en un mecanismo de validación y filtrado contextual. Este diseño aplica un conjunto de reglas (como la hora del día, el tipo de agente que emite la alerta o si el usuario ha pausado el sistema) y es crucial para el manejo de casos específicos, como la alerta por silencio prolongado en horario nocturno, o la interacción con el usuario mediante consultas verbales para validar la situación antes de enviar notificaciones externas. La existencia de esta capa asegura la preparación para la integración futura de variables contextuales adicionales (como detección de presencia o video) y garantiza la reducción de falsos positivos a medida que se refinan las reglas de filtrado. Su propósito final es asegurar que solo las situaciones críticas, validadas contextual y/o humanamente, generen una respuesta definitiva.

5. Capa de gestión de datos: Esta capa centraliza la persistencia y organización de la información recolectada y procesada por el sistema. Su propósito es almacenar los registros de eventos, tanto normales como anómalos, en estructuras que permitan su posterior análisis. Asimismo, prepara los conjuntos de datos necesarios para el reentrenamiento de los modelos de detección de anomalías, asegurando que el sistema pueda mejorar progresivamente su desempeño y adaptarse a nuevas condiciones acústicas en el entorno.
6. Capa de notificaciones: Tiene como responsabilidad la comunicación con el usuario final o con sistemas externos de monitoreo. Actualmente, este módulo envía alertas validadas a través de servicios de mensajería como Telegram y protocolos de correo electrónico (SMTP). Su diseño es extensible, lo que permite incorporar otros canales de comunicación en el futuro. La existencia de esta capa garantiza que la información crítica llegue de forma oportuna a los responsables de la toma de decisiones.

En la figura 13 se ilustra la arquitectura completa del sistema de monitoreo acústico, destacando las interacciones entre las diferentes capas y los agentes involucrados en el proceso de detección y notificación de anomalías.

### ***Selección de hardware y dispositivos Edge.***

Para la implementación del sistema, se realizó una evaluación de hardware con un enfoque en dispositivos de Edge Computing. La elección se centró en plataformas capaces de procesar datos localmente para reducir la latencia y la dependencia de la nube, como lo describen Shi y cols. (2016). En este contexto, se seleccionó la Raspberry Pi como la plataforma de desarrollo, dada su versatilidad para integrar componentes como micrófonos y su amplia conectividad, características que la hacen ideal para aplicaciones de IoT y análisis en tiempo real según Richardson y Wallace (2016).

La principal ventaja de este enfoque es que permite al sistema aprender las rutinas de su entorno específico, ya que los dispositivos permanecen fijos en un solo lugar. Esto requiere que los modelos de inteligencia artificial se ejecuten con los datos generados en dicho entorno. La alternativa (un gran servidor en la nube) sería muy costosa y poco práctica, pues exigiría mantener un modelo distinto para cada ubicación monitoreada, considerando que el sistema se compone de la interacción entre múltiples modelos. Por el contrario, un dispositivo edge como la Raspberry Pi resuelve este desafío al procesar los modelos localmente, permitiendo que cada unidad aprenda de manera autónoma sobre su entorno particular.



También se consideraron otros dispositivos edge, como el ESP32, pero se descartó debido a sus limitaciones de memoria y capacidad de procesamiento, que dificultarían la ejecución de modelos complejos de inteligencia artificial. Aunque el ESP32 es adecuado para tareas simples de detección de sonido basadas en umbrales, no cumple con los requisitos necesarios para implementar modelos avanzados como YAMNet o LSTM.

La comparación entre los distintos dispositivos edge se resume en el apéndice C.

## Capítulo V. Conclusiones y Recomendaciones

Como resultado de esta investigación, se desarrolló un sistema de monitoreo acústico basado en inteligencia artificial, diseñado para identificar sonidos relevantes en entornos domésticos y generar alertas oportunas en casos de emergencia. Este sistema integra tecnologías de procesamiento en el borde (Edge Computing) y modelos de clasificación de audio preentrenados, adaptándose a las condiciones variables de los espacios habitacionales, sin comprometer la privacidad de los usuarios. A continuación, se exponen las principales conclusiones y recomendaciones derivadas del estudio.

### Conclusiones

El análisis conceptual de la analítica de sonidos ambientales estableció la necesidad fundamental de ir más allá de los enfoques de intensidad o modelado secuencial simple (ARIMA/Márkov). Se determinó que la base metodológica del sistema radica en la caracterización semántica del audio (YAMNet) y el modelado contextual de sus secuencias (LSTM Autoencoder), lo que permitió definir la estrategia de detección de anomalías.

El diseño del sistema proporcionó una arquitectura de microservicios en el borde (Edge AI) sobre una Raspberry Pi, demostrando la posibilidad de cumplir con los requisitos de privacidad (procesamiento local) y modularidad (RNF1 y RNF4). Esta estructura de seis capas garantiza un flujo de trabajo adaptable para integrar la clasificación acústica y el análisis de secuencias de manera segura y escalable.

La implementación del sistema culminó con la consecución de un prototipo funcional que integra el clasificador semántico con el modelo LSTM Autoencoder. Se integró un proceso robusto de preprocesamiento, incluyendo el manejo de variables cíclicas y la codificación One-Hot de los eventos, lo que habilitó al modelo para aprender con fidelidad los patrones de comportamiento normales de las secuencias con baja latencia.

La validación del sistema confirmó la alta capacidad de detección del modelo LSTM Autoencoder mejorado, alcanzando un rendimiento de *Recall* del 100 y *Precision* superior al 90. Este resultado demuestra que el sistema es completamente funcional para la detección de emergencias, al eliminar por

completo los Falsos Negativos ( $FN = 0$ ), lo que asegura que ninguna situación crítica sea omitida.

Finalmente, la elaboración de la documentación garantiza la continuidad y replicabilidad de la solución. El manual detalla la arquitectura modular y los procedimientos técnicos para la configuración del entorno de ejecución en el borde, lo que asegura el mantenimiento del sistema como una herramienta de seguridad no invasiva y de gran utilidad para personas vulnerables.

## Recomendaciones

- Incorporar modelos de aprendizaje secuencial más avanzados: La integración de arquitecturas como transformers adaptados al procesamiento de audio permitiría mejorar la comprensión del contexto acústico y reducir la incidencia de falsos positivos o negativos en escenarios ambiguos.
- Desarrollar interfaces más intuitivas y accesibles: Se sugiere implementar una interfaz de usuario que permita a los usuarios configurar umbrales de alerta, definir eventos críticos personalizados y gestionar contactos de emergencia de forma amigable, incluyendo opciones accesibles para personas mayores.
- Ampliar los mecanismos de notificación mediante módulos GSM y servicios de notificaciones push: se recomienda diversificar e incrementar la robustez de los canales de envío de alertas mediante la incorporación de módulos GSM (Global System for Mobile Communications), los cuales permitirían el envío de mensajes SMS directamente desde el dispositivo sin necesidad de conexión a internet. Esto resulta especialmente útil en contextos con baja conectividad o en situaciones donde la red local pueda fallar durante una emergencia. De igual forma, se sugiere integrar notificaciones push móviles, a través de plataformas como Firebase Cloud Messaging (FCM), que permitirían alertas más inmediatas, personalizadas y con capacidad de interacción desde teléfonos inteligentes.
- Uso de ensamblajes de modelos: La combinación de múltiples modelos de detección, como CNNs y LSTMs, podría mejorar la precisión y robustez del sistema al aprovechar las fortalezas individuales de cada arquitectura. De esta manera, se podrían mitigar las debilidades de un solo modelo y aumentar la capacidad de generalización ante diversos escenarios acústicos.
- Sistema de retroalimentación del usuario: Implementar un mecanismo que permita a los usuarios confirmar o descartar alertas, ayudando al sistema a aprender y mejorar su precisión con el tiempo.
- Incorporar el uso de sensores de presencia como el C1001 mmWave Human Detection Sensor de Acconeer, que utiliza tecnología de radar para detectar la presencia y el movimiento de personas

en un entorno. Pudiendo detectar caídas, movimientos inusuales o la ausencia de movimiento, ritmo cardíaco y respiración, sin la necesidad de estar físicamente unido al cuerpo del usuario. Esto podría complementar el sistema de identificación de sonidos proporcionando una capa adicional de validación de estado del usuario o una serie de parámetros adicionales para el entrenamiento de modelos de aprendizaje automático.

## Referencias

- Aggarwal, C. C. (2016). An introduction to outlier analysis. En *Outlier analysis* (pp. 1–34). Springer.
- Bezold, J., Krell-Roesch, J., Eckert, T., Jekauc, D., y Woll, A. (2021). Sensor-based fall risk assessment in older adults with or without cognitive impairment: a systematic review. *European review of aging and physical activity*, 18(1), 15.
- Bobadilla Osses, A. (2010). *Cadenas de markov*. Descargado 2025-09-08, de <https://repositoriobibliotecas.uv.cl/serveruv/api/core/bitstreams/f4406bb7-5f33-4a41-8333-7d822360a0ed/content>
- Boehm, B. (1988). A spiral model of software development and enhancement. *ACM SIGSOFT Software Engineering Notes*, 11(4), 14–24. Descargado de <https://www.cse.msu.edu/~cse435/Homework/HW3/boehm.pdf>
- Boldt, M., Borg, A., Ickin, S., y Gustafsson, J. (2020). Anomaly detection of event sequences using multiple temporal resolutions and markov chains. *Knowledge and Information Systems*, 62(2), 669–686.
- Carlson, J. L. (2013). Action [j]. *Media. johnwiley. com. au*.
- Carmona, J. A. (2024). *Un “enchufe” wifi que avisa de caídas en casa. este es el innovador invento que quiere ayudar a los mayores*. Descargado 2025-09-08, de <https://www.xatakahome.com/seguridad-en-el-hogar/enchufe-wifi-que-avisa-caidas-casa-este-innovador-invento-que-quiere-ayudar-a-mayores>
- CEPAL. (2005). *Dinámica demográfica y desarrollo en américa latina y el caribe*. Descargado de <https://fiapam.org/wp-content/uploads/2012/10/lcl2235e-p.pdf>
- Doluí, K., y Kanti Datta, S. (2017). Comparison of edge computing implementations: Fog computing, cloudlet and mobile edge computing. En *Global internet of things summit (glots)*. doi: 10.1109/giots.2017.8016213
- García, J., Molina, J., y Berlanga, A. (2018). *Ciencia de datos: Técnicas analíticas*

- y aprendizaje estadístico en un enfoque práctico. Alfaomega. Descargado de [https://dlwqtxtslxzle7.cloudfront.net/64031156/Ciencia\\_de\\_datos\\_2018-libre.pdf](https://dlwqtxtslxzle7.cloudfront.net/64031156/Ciencia_de_datos_2018-libre.pdf)
- Gardner, J. R., Kusner, M. J., Xu, Z. E., Weinberger, K. Q., y Cunningham, J. P. (2014, junio). Bayesian optimization with inequality constraints. En *Proceedings of the 31st international conference on machine learning (icml)* (Vol. 32, pp. 937–945). JMLR Workshop and Conference Proceedings. Descargado de <https://proceedings.mlr.press/v32/gardner14.html>
- Gemmeke, J. F., Ellis, D. P., Freedman, D., Jansen, A., Lawrence, W., Moore, R. C., ... Ritter, M. (2017b). Audio set: An ontology and human-labeled dataset for audio events. En *2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 776–780).
- Gemmeke, J. F., Ellis, D. P. W., Freedman, D., Jansen, A., Lawrence, W., Moore, R. C., ... Ritter, M. (2017a). Audio Set: An Ontology and Human-Labeled Dataset for Audio Events. *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 776-780.
- Goldsborough, P. (2016). *A tour of tensorflow, proseminar data mining*. Descargado 2025-09-08, de <https://arxiv.org/pdf/1610.01178>
- Google. (s.f.). *YAMNet*. <https://www.kaggle.com/models/google/yamnet>. (Recuperado el 21 de octubre de 2025)
- Heaton, J. (2018). Ian goodfellow, yoshua bengio, and aaron courville: Deep learning: The mit press, 2016, 800 pp, isbn: 0262035618. *Genetic programming and evolvable machines*, 19(1), 305–307.
- Hernández, R., Fernández, C., y Baptista, P. (2014). *Metodología de la investigación* (6.<sup>a</sup> ed.). McGraw-Hill. Descargado de <https://www.esup.edu.pe/wp-content/uploads/2020/12/2.%20Hernandez,%20Fernandez%20y%20Baptista-Metodologa%20Investigacion%20Cientifica%206ta%20ed.pdf>
- Hochreiter, S., y Schmidhuber, J. (1997). Long short-term memory. *Neural computation*, 9(8), 1735–1780.
- Howard, A. G., Zhu, M., Chen, B., Wang, W., Weyand, T., Andreetto, M., ... Adam, H. (2017, Apr). MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications.

- arXiv preprint*. Descargado de <https://arxiv.org/abs/1704.04861>
- Hurtado, J. (2000). *Metodología de la investigación holística*. Descargado 2025-09-08, de <https://ayudacontextos.wordpress.com/wp-content/uploads/2018/04/jacqueline-hurtado-de-barrera-metodologia-de-investigacion-holistica.pdf>
- Hyndman, R. J., y Athanasopoulos, G. (2018). *Forecasting: Principles and practice* (2.<sup>a</sup> ed.). OTexts. Descargado de <https://otexts.com/fpp2/>
- Igba, J., Alemzadeh, K., Durugbo, C., y Eiriksson, E. T. (2016). Analysing rms and peak values of vibration signals for condition monitoring of wind turbine gearboxes. *Renewable Energy*, 91, 90–106.
- Liu, F. T., Ting, K. M., y Zhou, Z.-H. (2012). Isolation-based anomaly detection. *ACM Transactions on Knowledge Discovery from Data (TKDD)*, 6(1), 1–39.
- Luis-García, L. C., y Gómez, A. R. T. (2024). Desarrollo de aplicaciones iot: metodologías y estrategias. *European Public & Social Innovation Review*, 9, 1–18.
- Malhotra, P., Vig, L., Shroff, G., Agarwal, P., y cols. (2015). Long short term memory networks for anomaly detection in time series. En *Proceedings* (Vol. 89, p. 94).
- Malmberg, C., y Radszuweit, D. (2021). *Real-time audio classification on an edge device - using yamnet and tensorflow lite*. Descargado 2025-09-08, de <https://www.diva-portal.org/smash/record.jsf?pid=diva2%3A1605037&dswid=6895>
- Matas Soberón, J. J. (2024). *Una introducción a las cadenas de markov y sus aplicaciones*. Descargado 2025-09-08, de [https://dspace.uib.es/xmlui/bitstream/handle/11201/151803/Memoria\\_EPSU0697.pdf?sequence=1&isAllowed=y](https://dspace.uib.es/xmlui/bitstream/handle/11201/151803/Memoria_EPSU0697.pdf?sequence=1&isAllowed=y)
- Medina, M. (2019). *Edge computing para iot*. <https://openaccess.uoc.edu/bitstream/10609/91207/7/mmedinabarTFM0119memoria.pdf>. (Accessed: 2025-09-08)
- Mora, C. P., y Losada, J. L. (2023). Análisis de series temporales en estaciones meteorológicas para la predicción de la precipitación en la ciudad de manizales, colombia. *Revista de Climatología*, 23, 58–70.
- Naciones Unidas. (2022). *Envejecimiento*. Descargado 2025-09-08, de <https://www.un>

.org/es/global-issues/ageing

- Peña, F. A. V. (2016). Reciente evolución de los hogares unipersonales en España: una aproximación sociológica. *WPS Review International on Sustainable Housing and Urban Renewal: RI-SHUR*(3), 38–55.
- Pons Puig, J., y cols. (2019). Deep neural networks for music and audio tagging. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*. Descargado de <https://jordipons.me/media/PhD-Thesis-JordiPons.pdf>
- Pressman, R. (2010). *Ingeniería del software: Un enfoque práctico* (7.<sup>a</sup> ed.). McGraw-Hill. Descargado de [https://www.academia.edu/87171392/Ingeniera\\_de\\_software\\_enfoque\\_practico\\_Roger\\_Pressman\\_7ma\\_edicin](https://www.academia.edu/87171392/Ingeniera_de_software_enfoque_practico_Roger_Pressman_7ma_edicin)
- Provost, F., y Fawcett, T. (2013). *Data science for business: What you need to know about data mining and data-analytic thinking*. O'Reilly Media. Descargado de [https://www.researchgate.net/publication/256438799\\_Data\\_Science\\_for\\_Business](https://www.researchgate.net/publication/256438799_Data_Science_for_Business)
- Ralla, E. (2024). *Hallan el cadáver en zaragoza de un hombre que llevaba muerto varios días en su casa*. Descargado 2025-09-08, de <https://www.heraldo.es/noticias/aragon/zaragoza/2024/03/22/encuentran-cadaver-zaragoza-hombre-muerto-varios-dias-casa-1720901.html>
- Reis, M. J., y Serôdio, C. (2025). Edge ai for real-time anomaly detection in smart homes. *Future Internet*, 17(4), 179.
- Richardson, M., y Wallace, S. (2016). *Getting started with raspberry pi: An introduction to the fastest-selling computer in the world* (4.<sup>a</sup> ed.). Maker Media, Inc. Descargado de [https://books.google.co.ve/books/about/Getting\\_Started\\_With\\_Raspberry\\_Pi.html?id=w4CkDAAQBAJ&redir\\_esc=y](https://books.google.co.ve/books/about/Getting_Started_With_Raspberry_Pi.html?id=w4CkDAAQBAJ&redir_esc=y)
- Russell, S., y Norvig, P. (2022). *Artificial intelligence: A modern approach* (4.<sup>a</sup> ed.). Pearson. Descargado de <http://lib.ysu.am/disciplines/bk/efdd4d1d4c2087fe1cbe03d9ced67f34.pdf>
- Sabo, M. (2020). *Nestjs*. Descargado 2025-09-08, de <https://zir.nsk.hr/islandora/object/mathos:441>
- Shi, W., Cao, J., Zhang, Q., Li, Y., y Xu, L. (2016). Edge computing: Vision and challenges. *IEEE*



- Internet of Things Journal*, 3(5), 637–646. doi: 10.1109/JIOT.2016.2579198
- Tamayo, M. (2004). *El proceso de la investigación científica*. Limusa. Descargado de [https://www.gob.mx/cms/uploads/attachment/file/227860/El\\_proceso\\_de\\_la\\_investigaci\\_n\\_cient\\_fica\\_Mario\\_Tamayo.pdf](https://www.gob.mx/cms/uploads/attachment/file/227860/El_proceso_de_la_investigaci_n_cient_fica_Mario_Tamayo.pdf)
- Tanenbaum, A. S., y Van Steen, M. (2007). *Distributed systems: principles and paradigms*. Pearson Prentice Hall.
- Torija, A., Ruiz, P., y Ramos-Diao, A. (2018). Metodología para la identificación de eventos sonoros anómalos. En *Congreso nacional de acústica – tecniacústica 2018*. Descargado de <https://documentacion.sea-acustica.es/publicaciones/Coimbra08/id206.pdf>
- Tran, T., y Lundgren, J. (2020). Drill fault diagnosis based on the scalogram and mel spectrogram of sound signals using artificial intelligence. *Ieee Access*, 8, 203655–203666.
- Upton, E., y Halfacree, G. (2020). *Raspberry pi user guide* (4.<sup>a</sup> ed.). John Wiley & Sons. Descargado de <https://www.perlego.com/book/997788/raspberry-pi-user-guide-pdf>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, 30.
- Yuill, S., y Halpin, H. (2006). *Python*. <https://citeseerx.ist.psu.edu/document?repid=rep1&type=pdf&doi=1f2ee3831eebfc97bfafd514ca2abb7e2c5c86bb>. (Accessed: 2025-09-08)

Anexos

# Anexo A. Dispositivo Raspberry Pi 4 Model B




Figura 14: Arquitectura del Raspberry Pi 4 Model B

## Anexo B. Construcción del Isolation Forest (Bosque de Aislamiento)




Figura 15: Algoritmo de construcción del Isolation Forest

Anexo C. Numero de datos de entrenamiento por categoría de sonido




Figura 16: Número de datos de entrenamiento por categoría de sonido

index;mid;display_name
0;/m/09x0r;Hablar
1;/m/0ytgt;Nino hablando; bebe hablando
2;/m/01h8n0;Conversacion
3;/m/02qldy;Narracion; monologo
4;/m/0261r1;Balbuceo
5;/m/0brhx;sintetizador de voz
6;/m/07p6fty;Vociferar
7;/m/07q4ntr;Bramido
8;/m/07rwj3x;Alarido
9;/m/07sr1lc;Gritar
10;/t/dd00135;Ninos vociferando
11;/m/03qc9zr;Grito
12;/m/02rtxl;Susurro
13;/m/01j3sz;Risa
14;/t/dd00001;Bebe riendo
15;/m/07r660_;Risilla
16;/m/07s04w4;Risa disimulada
17;/m/07sq110;Carcajada
18;/m/07rgt08;Risa moderada
19;/m/0463cq4;Llorando; sollozando
20;/t/dd00002;Llanto de bebe; llanto de infante
21;/m/07qz6j3;Gemido
22;/m/07qw_06;Llorar; gemir
23;/m/07plz5l;Suspiro
24;/m/015lz1;Cantando
25;/m/0l14jd;Coro
26;/m/01swy6;Tiroles
27;/m/02bk07;Corear
28;/m/01c194;Mantra
29;/t/dd00005;Ninos cantando
30;/t/dd00006;canto sintetico
31;/m/06bxc;Golpecitos
32;/m/02fxyj;Tarareo
33;/m/07s2xch;Quejido
34;/m/07r4k75;Gruñido
35;/m/01w250;Silbido
36;/m/0lyf6;Respiracion
37;/m/07mzm6;Resuello
38;/m/01d3sd;Ronquidos
39;/m/07s0dtb;Resoplido
40;/m/07pyy8b;Jadear
41;/m/07q0yl5;Bufido
42;/m/01b_21;Tos
43;/m/0dl9sf8;Despejar la garganta
44;/m/01hsr_;Estornudo
45;/m/07ppn3j;Oler
46;/m/06h7j;Correr
47;/m/07qv_x_;Barajar
48;/m/07pbtc8;Caminar; pasos

49;/m/03cczk;Masticar; mordisquear
50;/m/07pdhp0;Morder
51;/m/0939n_;Gargarizar
52;/m/01g90h;Ruido estomacal
53;/m/03q5_w;Eructos; eructar
54;/m/02p3nc;Hipo
55;/m/02_nn;Pedo
56;/m/0k65p;Manos
57;/m/025_jnm;Chasquear los dedos
58;/m/0l15bq;Aplaudir
59;/m/01jg02;Sonidos del corazon; latidos del corazon
60;/m/01jg1z;Soplo cardiaco
61;/m/053hz1;Animar
62;/m/028ght;Ovacion
63;/m/07rkbfh;Charla
64;/m/03qtwd;Multitud
65;/m/07qfr4h;Alboroto; ruido del habla; balbuceo del habla
66;/t/dd00013;Ninos jugando
67;/m/0jbk;Animal
68;/m/068hy;Animales domesticos; mascotas
69;/m/0bt9lr;Perro
70;/m/05tny_;LadRAR
71;/m/07r_k2n;Chillido
72;/m/07qf0zm;Aullido
73;/m/07rc7d9;Guau-guau
74;/m/0ghcn6;Grunendo
75;/t/dd00136;Gemido (perro)
76;/m/01yrx;Gato
77;/m/02yds9;Ronroneo
78;/m/07qrkrw;Miau
79;/m/07rjwbb;Siseo
80;/m/07r81j2;Chillar
81;/m/0ch8v;Ganado; animales de granja; animales de trabajo
82;/m/03k3r;Caballo
83;/m/07rv9rh;Clip-clop
84;/m/07q5rw0;Relincho; Relinchito
85;/m/01xq0k1;Ganado bovino
86;/m/07rpkh9;Muu
87;/m/0239kh;Cencerro
88;/m/068zj;Cerdo
89;/t/dd00018;Oink
90;/m/03fwl;Cabra
91;/m/07q0h5t;Baa (Cabra; Oveja)
92;/m/07bgp;Oveja
93;/m/025rv6n;Ave de corral
94;/m/09b5t;Pollo; gallo
95;/m/07st89h;Cacareo
96;/m/07qn5dc;Cacareo; quiquirikii
97;/m/01rd7k;Pavo
98;/m/07svc2k;Gluglu

99;/m/09ddx;Pato
100;/m/07qdb04;Cuac
101;/m/0dbvp;Ganso
102;/m/07qwf61;Graznido
103;/m/01280g;Animales Salvajes
104;/m/0cdnk;Gatos rugiendo (leones; tigres)
105;/m/04cvmfc;Rugido
106;/m/015p6;Pajaro
107;/m/020bb7;Vocalizacion de pajaros; canto de pajaros; canto de pajaros
108;/m/07pggtn;Trino
109;/m/07sx8x_;Graznido
110;/m/0h0rv;Paloma; tortola
111;/m/07r_25d;Coo
112;/m/04s8yn;Cuervo
113;/m/07r5c2p;Caw
114;/m/09d5_;Buho
115;/m/07r_80w;Hoot
116;/m/05_wcq;Vuelo de pajaro; batir de alas
117;/m/01z5f;Caninos; perros; lobos
118;/m/06hps;Roedores; ratas; ratones
119;/m/04rmv;Raton
120;/m/07r4gkf;Golpeteo
121;/m/03vt0;Insecto
122;/m/09xqv;Grillo
123;/m/09f96;Mosquito
124;/m/0h2mp;Mosca; Mosca domestica
125;/m/07pjwq1;Zumbido
126;/m/01h3n;Abeja; avispa; etc.
127;/m/09ld4;Rana
128;/m/07st88b;Croar
129;/m/078jl;Serpiente
130;/m/07qn4z3;Cascabel
131;/m/032n05;Vocalizacion de ballenas
132;/m/04rlf;Musica
133;/m/04szw;Instrumento musical
134;/m/0fx80y;Instrumento de cuerda pulsada
135;/m/0342h;Guitarra
136;/m/02sgy;Guitarra electrica
137;/m/018vs;Bajo
138;/m/042v_gx;Guitarra acustica
139;/m/06w87;Guitarra de acero; guitarra slide
140;/m/01glhc;Tapping (tecnica de guitarra)
141;/m/07s0s5r;Rasguear
142;/m/018j2;Banjo
143;/m/0jtg0;Sitar
144;/m/04rzd;Mandolin
145;/m/01bns_;Zither
146;/m/07xzm;Ukulele
147;/m/05148p4;Teclado (musical)
148;/m/05r5c;Piano



149;/m/01s0ps;Piano electrico
150;/m/013y1f;Organo
151;/m/03xq_f;Organo electrico
152;/m/03gvt;Organo de hammond
153;/m/0l14qv;Sintetizador
154;/m/01v1d8;Sampler
155;/m/03q5t;Clavecin
156;/m/0l14md;Percusion
157;/m/02hnl;Bateria
158;/m/0cfd;Caja de ritmos
159;/m/026t6;Tambor
160;/m/06rvn;Caja (instrumento)
161;/m/03t3fj;Rimshot
162;/m/02k_mr;Redoble de tambores
163;/m/0bm02;Bombo
164;/m/011k_j;Timpanos
165;/m/01p970;Tabla
166;/m/01qbl;Platillo
167;/m/03qtq;Hi-hat
168;/m/01sm1g;Bloque de madera
169;/m/07brj;Pandereta
170;/m/05r5wn;Sonajero (instrumento)
171;/m/0xzly;Maraca
172;/m/0mbct;Gong
173;/m/016622;Campanas tubulares
174;/m/0j45pbj;Percusion de mazo
175;/m/0dwsp;Marimba; xilofono
176;/m/0dwtp;Campanas
177;/m/0dwt5;Vibrofono
178;/m/0l156b;Cacerola
179;/m/05pd6;Orquesta
180;/m/01kcd;instrumento de latin
181;/m/0319l;Corno frances
182;/m/07gql;Trompeta
183;/m/07c6l;Trombon
184;/m/0l14_3;Instrumento de cuerda frotada
185;/m/02qmj0d;Seccion de cuerdas
186;/m/07y_7;Violin; violin tradicional
187;/m/0d8_n;Pizzicato
188;/m/01xqw;Violonchelo
189;/m/02fsn;Contrabajo
190;/m/085jw;Instrumento de viento; instrumento de viento de madera
191;/m/0l14j_;Flauta
192;/m/06ncr;Saxofon
193;/m/01wy6;Clarinete
194;/m/03m5k;Arpa
195;/m/0395lw;Campana
196;/m/03w41f;Campana de la iglesia
197;/m/027m70_;Cascabel
198;/m/0gy1t2s;Timbre de bicicleta

199;/m/07n_g;Diapason
200;/m/0f8s22;Campanilla
201;/m/026fgl;Carilli¿½n de viento
202;/m/0150b9;Cambio de repique (campanologia)
203;/m/03qjg;Harmonica
204;/m/0mkg;Acordeon
205;/m/0192l;Gaita
206;/m/02bxd;Didyerido
207;/m/0l14l2;Shofar
208;/m/07kc_ ;Theremin
209;/m/0l14t7;Cuenco tibetano
210;/m/01hgjl;Scratching (movimiento de discos)
211;/m/064t9;Musica pop
212;/m/0glt670;Musica hip hop
213;/m/02cz_7;Beatboxing
214;/m/06by7;Musica rock
215;/m/03lty;Heavy metal
216;/m/05r6t;Punk rock
217;/m/0dls3;Grunge
218;/m/0dl5d;Rock progresivo
219;/m/07sbbz2;Rock and roll
220;/m/05w3f;Rock psicodelico
221;/m/06j6l;ritmo y blues
222;/m/0gywn;musica soul
223;/m/06cqb;Reggae
224;/m/01lyv;Pais
225;/m/015y_n;Musica swing
226;/m/0gg8l;pasto azul
227;/m/02x8m;Canguelo
228;/m/02w4v;Musica folkli¿½rica
229;/m/06j64v;musica del medio oriente
230;/m/03_d0;Jazz
231;/m/026z9;Disco
232;/m/0ggq0m;Musica clasica
233;/m/05lls;opera
234;/m/02lkt;musica electronica
235;/m/03mb9;musica house
236;/m/07gxw;tecno
237;/m/07s72n;dubstep
238;/m/0283d;bateria y bajo
239;/m/0m0jc;electronica
240;/m/08cyft;musica electronica de baile
241;/m/0fd3y;musica ambiental
242;/m/07lnk;musica trance
243;/m/0g293;musica de latinoamerica
244;/m/0ln16;musica salsa
245;/m/0326g;Flamenco
246;/m/0155w;Blues
247;/m/05fw6t;musica para ninos
248;/m/02v2lh;Musica de la nueva era

249;/m/0y4f8;Musica vocal
250;/m/0z9c;a capella
251;/m/0164x2;Musica de ï¿½frica
252;/m/0145m;afrobeat
253;/m/02mscn;musica cristiana
254;/m/016cjb;musica gospel
255;/m/028sqc;Musica de Asia
256;/m/015vgc;musica carnitica
257;/m/0dq0md;Musica de Bollywood
258;/m/06rqw;ska
259;/m/02p0sh1;musica tradicional
260;/m/05rwpb;musica independiente
261;/m/074ft;Cancion
262;/m/025td0t;Musica de fondo
263;/m/02cjck;tema musical
264;/m/03r5q_;Jingle (musica)
265;/m/0l14gg;Musica de banda sonora
266;/m/07pkxdp;Cancion de cuna
267;/m/01z7dr;musica de videojuegos
268;/m/0140xf;musica navidena
269;/m/0ggx5q;musica de baile
270;/m/04wptg;musica de boda
271;/t/dd00031;musica feliz
272;/t/dd00033;musica triste
273;/t/dd00034;musica tierna
274;/t/dd00035;musica emocionante
275;/t/dd00036;musica enojada
276;/t/dd00037;musica aterradora
277;/m/03m9d0z;Viento
278;/m/09t49;hojas susurrantes
279;/t/dd00092;Ruido del viento (microfono)
280;/m/0jb2l;Tormenta
281;/m/0ngt1;Trueno
282;/m/0838f;Agua
283;/m/06mb1;Lluvia
284;/m/07r10fb;Gota de agua
285;/t/dd00038;Lluvia en superficie
286;/m/0j6m2;Arroyo
287;/m/0j2kx;Cascada
288;/m/05kq4;Oceano
289;/m/034srq;olas; surf
290;/m/06wzb;Vapor
291;/m/07swgks;Gluglu
292;/m/02_41;Fuego
293;/m/07pzfmf;Crepitar
294;/m/07yv9;Vehiculo
295;/m/019jd;Barco; Vehiculo acui¿½tico
296;/m/0hsrw;Velero; velero
297;/m/056ks2;Bote de remos; canoa; kayak
298;/m/02rlv9;Lancha motora; lancha rapida

299;/m/06q74;Barco
300;/m/012f08;Vehiculo de motor (carretera)
301;/m/0k4j;Auto
302;/m/0912c9;Bocina de vehi½culo; bocina de coche; bocina
303;/m/07qv_d5;Sonar
304;/m/02mfyn;alarma de coche
305;/m/04gxbd;elevelunas electricos; elevelunas electricos
306;/m/07rknqz;derrapando
307;/m/0h9mv;Chirrido de neumaticos
308;/t/dd00134;Coche pasando por
309;/m/0ltv;Coche de carreras; carreras de autos.
310;/m/07r04;Camion
311;/m/0gvgw0;Freno de aire
312;/m/05x_td;Bocina de aire; bocina de camion
313;/m/02rhddq;Pitidos de marcha atras
314;/m/03cl9h;Cami½n de helados; furgoneta de helados.
315;/m/01bjv;Autobi½s
316;/m/03j1ly;vehi½culo de emergencia
317;/m/04qvtq;Coche de polici½a (sirena)
318;/m/012n7d;Ambulancia (sirena)
319;/m/012ndj;Camion de bomberos; camion de bomberos (sirena)
320;/m/04_sv;Motocicleta
321;/m/0btp2;Ruido del trafico; ruido de la carretera.
322;/m/06d_3;Transporte ferroviario
323;/m/07jdr;Tren
324;/m/04zmvq;silbato de tren
325;/m/0284vy3;Bocina de tren
326;/m/01g50p;Vagon de ferrocarril; vagon de tren.
327;/t/dd00048;Ruedas de tren chirriando
328;/m/0195fx;Metro; metro; metro
329;/m/0k5j;Aeronave
330;/m/014yck;motor de avion
331;/m/04229;motor a reaccion
332;/m/02l6bg;Helice
333;/m/09ct_;Helicoptero
334;/m/0cmf2;Avion de ala fija; avion.
335;/m/0199g;Bicicleta
336;/m/06_fw;Monopatin
337;/m/02mk9;Motor
338;/t/dd00065;Motor ligero (alta frecuencia)
339;/m/08j51y;Taladro dental; taladro de dentista.
340;/m/01yg9g;Cortacesped
341;/m/01j4z9;motosierra
342;/t/dd00066;Motor medio (frecuencia media)
343;/t/dd00067;Motor pesado (baja frecuencia)
344;/m/01h82_;Golpeteo del motor
345;/t/dd00130;Arranque del motor
346;/m/07pb8fc;De marcha en vacio
347;/m/07q2z82;Acelerando; acelerando; vroom
348;/m/02dgv;Puerta

349;/m/03wwcy;Timbre de la puerta
350;/m/07r67yg;ding dong
351;/m/02y_763;Puerta corrediza
352;/m/07rjzl8;Golpe
353;/m/07r4wb8;Golpear
354;/m/07qcpqn;Grifo
355;/m/07q6cd_;Chirrido
356;/m/0642b4;Armario abierto o cerrado
357;/m/0fqfqc;Cajón abierto o cerrado
358;/m/04brg2;Platos; ollas y sartenes
359;/m/023pjk;cubiertos; cubiertos
360;/m/07pn_8q;Picar (comida)
361;/m/0dxrf;Freir (comida)
362;/m/0fx9l;Microondas
363;/m/02pjr4;Licuadora
364;/m/02jz0l;Grifo de agua; grifo
365;/m/0130jx;Fregadero (llenado o lavado)
366;/m/03dnzn;Bañera (llenado o lavado)
367;/m/03wvsk;Secador de pelo
368;/m/01jt3m;Descarga del inodoro
369;/m/012xff;Cepillo de dientes
370;/m/04fgwm;cepillo de dientes electrico
371;/m/0d31p;Aspiradora
372;/m/01s0vc;Cremallera (ropa)
373;/m/03v3yw;llaves tintineando
374;/m/0242l;Moneda (cayendo)
375;/m/01lsmm;Tijeras
376;/m/02g901;Afeitadora electrica; afeitadora electrica.
377;/m/05rj2;barajar cartas
378;/m/0316dw;Mecanografia
379;/m/0c2wf;Maquina de escribir
380;/m/01m2v;teclado de computadora
381;/m/081rb;Escribiendo
382;/m/07pp_mv;Alarma
383;/m/07cx4;Telefono
384;/m/07pp8cl;Suena el timbre del telefono
385;/m/01hnzm;Tono de llamada
386;/m/02c8p;Marcacion telefonica; DTMF
387;/m/015jpf;Tono de marcacion
388;/m/01z47d;senal de ocupado
389;/m/046dlr;Despertador
390;/m/03kmc9;Sirena
391;/m/0dgbq;sirena de defensa civil
392;/m/030rvx;Zumbador
393;/m/01y3hg;Detector de humo; alarma de humo.
394;/m/0c3f7m;Alarma de incendios
395;/m/04fq5q;Sirena
396;/m/0l156k;Silbar
397;/m/06hck5;silbato de vapor
398;/t/dd00077;Mecanismos

399;/m/02bm9n;Trinquete; trinquete
400;/m/01x3z;Reloj
401;/m/07qjznt;Garrapata
402;/m/07qjznl;tic-tac
403;/m/0l7xg;Engranajes
404;/m/05zc1;poleas
405;/m/0llzx;Miğ½quina de coser
406;/m/02x984l;ventilador mecanico
407;/m/025wky1;Aire acondicionado
408;/m/024dl;Caja registradora
409;/m/01m4t;Impresora
410;/m/0dv5r;Ciğ½mara
411;/m/07bjf;Ciğ½mara reflex de un solo objetivo
412;/m/07k1x;Herramientas
413;/m/03l9g;Martillo
414;/m/03p19w;Martillo neumatico
415;/m/01b82r;Aserradura
416;/m/02p01q;Limar (escofina)
417;/m/023vsd;Lijado
418;/m/0_ksk;Herramienta electrica
419;/m/01d380;Perforar
420;/m/014zdl;Explosion
421;/m/032s66;Disparo; disparos
422;/m/04zjc;Ametralladora
423;/m/02z32qm;Descarga cerrada
424;/m/0_1c;Fuego de artilleria
425;/m/073cg4;pistola de gorra
426;/m/0g6b5;Fuegos artificiales
427;/g/122z_qxw;Petardo
428;/m/07qsvvw;Explosion; estallido
429;/m/07pxg6y;Erupcion
430;/m/07qqyl4;Auge
431;/m/083vt;Madera
432;/m/07pczhz;Cortar
433;/m/07pl1bw;Astilla
434;/m/07qs1cx;Grieta
435;/m/039jq;Vaso
436;/m/07q7njin;Chin; tintineo
437;/m/07rn7sz;Romper
438;/m/04k94;Liquido
439;/m/07rrlb6;Salpicar; salpicar
440;/m/07p6mqd;Pegar
441;/m/07qlwh6;Chapotear
442;/m/07r5v4s;Goteo
443;/m/07prgkl;Derramar
444;/m/07pqc89;Goteo; regateo
445;/t/dd00088;Chorro
446;/m/07p7b8y;Llenar (con liquido)
447;/m/07qlf79;Pulverizacion
448;/m/07ptzwd;Bomba (liquido)

449;/m/07ptfmf;Remover
450;/m/0dv3j;Hirviendo
451;/m/0790c;Sonar
452;/m/0dl83;Flecha
453;/m/07rqsjt;Whoosh; swoosh; silbido
454;/m/07qnq_y;Golpe; golpe
455;/m/07rrh0c;Tonk
456;/m/0b_fwt;sintonizador electronico
457;/m/02rr_;Unidad de efectos
458;/m/07m2kt;efecto coro
459;/m/018w8;rebote de baloncesto
460;/m/07pws3f;Estallido
461;/m/07ryjzk;Bofetada; bofetada
462;/m/07rdhzs;Golpe; golpe
463;/m/07pjjrj;Aplastar; chocar
464;/m/07pc8lb;Rotura
465;/m/07pqn27;Fuerte
466;/m/07rbp7_;Latigo
467;/m/07pyf11;Solapa
468;/m/07qb_dv;Rascar
469;/m/07qv4k0;Raspar
470;/m/07pdjhy;Frotar
471;/m/07s8j8t;Rollo
472;/m/07plct2;Aplastante
473;/t/dd00112;Arrugando; arrugando
474;/m/07qcx4z;lagrimeo
475;/m/02fs_r;Bip; bip
476;/m/07qwdck;Silbido
477;/m/07phxs1;Timbre
478;/m/07rv4dm;Sonido metálico
479;/m/07s02z0;Chillido
480;/m/07qh7jl;Crujir
481;/m/07qwyj0;Crujido
482;/m/07s34ls;Zumbido
483;/m/07qmpdm;Estrépito
484;/m/07p9k1k;Chisporrotear
485;/m/07qc9xj;Haciendo clic
486;/m/07rwm0c;Clic-clac
487;/m/07phhsh;Retumbar
488;/m/07qyrcz;Plaf
489;/m/07qfgpx;Jingle; tintineo
490;/m/07rcgpl;Tararear
491;/m/07p78v5;Gusto
492;/t/dd00121;boing
493;/m/07s12q4;Crujido
494;/m/028v0c;Silencio
495;/m/01v_m0;onda sinusoidal
496;/m/0b9m1;Armónico
497;/m/0hdsk;tono de chirrido
498;/m/0c1dj;efecto de sonido

499;/m/07pt_g0;Legumbres
500;/t/dd00125;Interior; habitacion pequena.
501;/t/dd00126;Interior; gran salon o recibidor.
502;/t/dd00127;Interior; espacio publico.
503;/t/dd00128;Exterior; urbano o artificial
504;/t/dd00129;Exterior; rural o natural
505;/m/01b9nn;Reverberacion
506;/m/01jnbd;Eco
507;/m/096m7z;Ruido
508;/m/06_y0by;Ruido ambiental
509;/m/07rgkc5;Estatico
510;/m/06xkwv;Zumbido de red
511;/m/0g12c5;Distorsion
512;/m/08p9q4;efecto local
513;/m/07szfh9;Cacofonia
514;/m/0chx_;ruido blanco
515;/m/0cj0r;ruido rosa
516;/m/07p_0gm;Palpitante
517;/m/01jwx6;Vibracion
518;/m/07c52;Television
519;/m/06bz3;Radio
520;/m/07hvw1;Grabacion de campo



## Apéndices

## Apéndice A. Representación cíclica del tiempo mediante funciones trigonométricas




Figura 17: Visualización de las funciones seno y coseno

GeoGebra: Generación de las funciones seno y coseno usando las expresiones:

`Sequence((x, sin(x)), x, 0, 2π, π/6)` y

`Sequence((x, cos(x)), x, 0, 2π, π/6)`




Figura 18: Visualización discreta del comportamiento cíclico del tiempo

GeoGebra: Generación de puntos discretos sobre la circunferencia usando la expresión:

`Sequence((cos(2π * n / 86400), sin(2π * n / 86400)), n, 0, 86400, 3600)`

La figura incluye dos líneas auxiliares que recorren la circunferencia: una horizontal (coseno) y una vertical (seno), generadas dinámicamente mediante un deslizador  $t$  con paso de 600 segundos. Estas líneas intersectan en el punto  $(x, y)$ , representando la posición temporal proyectada en coordenadas trigonométricas.




Figura 19: Curva paramétrica continua del tiempo sobre el círculo unitario

GeoGebra: Generación de la curva mediante las expresiones:

$x(t) = \cos(2\pi * t / 86400),$                        $y(t) = \sin(2\pi * t / 86400),$   
`Curve(x(t), y(t), t, 0, 86400)`

La figura muestra una curva paramétrica continua que representa el tiempo sobre el círculo unitario mediante funciones trigonométricas. Cada instante se proyecta como un punto único definido por  $x(t) = \cos(\frac{2\pi t}{86400})$  y  $y(t) = \sin(\frac{2\pi t}{86400})$ , donde  $t$  es el número de segundos desde las 00:00. Esta codificación garantiza continuidad angular, permitiendo que modelos de simulación o aprendizaje automático interpreten correctamente la naturaleza cíclica del tiempo sin ambigüedades en los extremos del día.

## Apéndice B. Algoritmos de los distintos agentes

```

1 Algoritmo Agente Isolation Forest
2
3 Agente_IsolationForest()
4   LeerConfiguración() // tasas, umbrales, ventanas
5   InicializarEstado() // colas, flags, historial
6
7 Escuchar()
8   Suscribirse(canal_audio)
9   Mientras true
10      msg ← LeerMensaje()
11      Si msg válido (texto + timestamp)
12         evento ← NormalizarEvento(msg) // agrega date y label
13         Agregar(buffer, evento)
14         Si |buffer| > MAX_BUFFER
15            QuitarMasAntiguo(buffer)
16      EsperarBreve()
17
18 Procesar()
19   Mientras true
20      Si |buffer| > 0
21         lote ← Copia(buffer)
22         df ← ConvertirADataFrame(lote)
23         X ← GenerarCaracterísticas(df)
24         resultados ← Predecir(Modelo, X) // etiquetas y puntajes
25         anomalías ← Filtrar(resultados, pred = -1)
26         Para cada label único en anomalías
27            ConstruirMensaje(label, fecha, score)
28            Publicar(canal_alertas, mensaje)
29      EsperarIntervaloProceso()

```

Figura 20: Algoritmo del agente de detección de anomalías basado en Isolation Forest

```

1 Algoritmo Agente LSTM
2
3 Agente_LSTM()
4     LeerConfiguración() // tasas, umbrales, ventanas
5     InicializarEstado() // colas, flags, historial
6
7 Escuchar()
8     Suscribirse(canal_entrada)
9     Mientras true
10        msg ← LeerMensaje()
11        Si msg es válido (tiene texto y timestamp)
12            evento ← ConstruirEvento(msg)
13            Agregar(buffer, evento)
14            Si |buffer| > SEQ_LEN
15                EliminarMásAntiguo(buffer)
16        EsperarBreve()
17
18 Analizar()
19     Mientras true
20         Si |buffer| ≥ SEQ_LEN
21             serie ← Copia(buffer)
22             Para cada evento en serie
23                 CalcularFechaYHora()
24                 DerivarCaracterísticasCíclicas(día, tiempo)
25             labels_enc ← CodificarEtiquetas(serie.labels)
26             X ← Combinar(labels_enc, características_temporales)
27             X2 ← ReconstrucciónModelo(X)
28             mse ← ErrorCuadráticoMedio(X, X2)
29             Si mse > umbral
30                 alerta ← ConstruirAlerta(serie, mse)
31                 Publicar(canal_alertas, alerta)
32                 Limpiar(buffer)
33     EsperarIntervaloCorto()

```

Figura 21: Algoritmo del agente de predicción basado en LSTM

```

1 Algoritmo Agente Silencio
2
3 Agente_Silencio()
4     LeerConfiguración() // tasas, umbrales, ventanas
5     InicializarEstado() // colas, flags, historial
6     IniciarStreamAudio(callback_audio)
7
8 CapturaYProcesamientoAudio()
9     Mientras true
10         frame ← ObtenerDeCola(timeout)
11         variance ← CalcularVarianza(frame)
12         actividad ← variance > UMBRAL
13         ActualizarUltimaActividad(actividad)
14         AñadirHistorial(frame, variance, actividad)
15         RecortarHistorialSiExcedeVentana()
16         Si HistorialInsuficiente()
17             Continuar
18         recent ← Últimos(STABILITY_FRAMES)
19         activity_count ← ContarActividad(recent)
20         silence_count ← STABILITY_FRAMES - activity_count
21         frames_sugieren_actividad ← activity_count > silence_count
22         hold ← TiempoDesdeUltimaActividad() ≤ HOLD_TIME
23         estado_actual_actividad ← frames_sugieren_actividad 0 hold
24         Si CambioASilencio(estado_actual_actividad)
25             PublicarEstado("silence", métricas)
26         Si CambioAActividad(estado_actual_actividad)
27             PublicarEstado("activity", métricas)
28
29 PublicarEstado(tipo, datos)
30
31 Fin

```

Figura 22: Algoritmo del agente de detección de silencio

Apéndice C. Verificación del sistema de monitoreo acústico

Requerimiento	Descripción	Entrada	Salida	Criterio de Aceptación
R1	Captura continua del audio ambiental a través de micrófonos.	Señales de audio del entorno a través del hardware del micrófono.	Eventos discretos etiquetados del audio.	El sistema debe estar activo y registrando datos en todo momento.
R2	Procesamiento del audio capturado para su caracterización.	Flujo de datos de audio.	Clasificación del sonido (ej. voz, silencio, golpe).	El sistema debe etiquetar correctamente la señal de audio que recibe en todo momento.
R3	Caracterizar el perfil de la actividad acústica "típica" del entorno, basado en la estacionalidad de los eventos sonoros clasificados.	Secuencia de eventos sonoros clasificados	Perfil acústico del comportamiento normal del entorno	El sistema construye un modelo del patrón sonoro habitual considerando variaciones temporales y estacionalidad.

Requerimiento	Descripción	Entrada	Salida	Criterio de Aceptación
R4	procesar y comparar la actividad sensada de manera inmediata con el perfil de normalidad para detectar patrones anómalos con la mínima latencia posible	Identificación de una anomalía o evento atípico.	Detectar desviaciones significativas del patrón normal con baja latencia para respuesta oportuna.	
R5	El sistema envía notificaciones de emergencia si la anomalía es crítica o el usuario no responde.	Falta de respuesta del usuario o gravedad de la anomalía	Envío de notificaciones.	El sistema es capaz de enviar una alerta sin la intervención del usuario.

Tabla 5: Requerimientos del sistema acústico



Apéndice D. Cuadro comparativo de microcontroladores

Característica	Raspberry Pi 4 model B	NVIDIA Jetson Nano	Google Coral (TPU)	Arduino (ej. UNO/Mega)	ESP32
Capacidad de Cómputo	Procesador ARM de alto rendimiento multinúcleo.	Procesador ARM de cuatro núcleos y GPU con 128 núcleos NVIDIA CUDA.	Procesador ARM, pero su poder de IA proviene de una TPU especializada.	Microcontrolador de 8 o 32 bits.	Microcontrolador de 32 bits con Wi-Fi y Bluetooth.
Memoria y almacenamiento	2-8 GB RAM, microSD hasta 1 TB	4 GB RAM, microSD hasta 128 GB	1 GB RAM, microSD, almacenamiento interno limitado	2-8 KB RAM, sin almacenamiento persistente	512 KB RAM, soporte microSD externo
Costo	65\$ (Amazon)	165\$ (AliBaba)	144\$	27\$	Entre 10\$ y 20\$ (Amazon)

Tabla 6: Cuadro comparativo de microcontroladores

## Apéndice E. Manual de Usuario

### Introducción

Este sistema es una solución basada en inteligencia artificial, diseñada para identificar sonidos ambientales y generar alertas en situaciones de emergencia que puedan indicar que una persona se encuentra en una posición de vulnerabilidad.

El objetivo principal del sistema es ofrecer un monitoreo continuo, discreto y no invasivo, capaz de detectar eventos sonoros anómalos (gritos de auxilio, caídas, rotura de cristales o silencios prolongados) y notificar de manera inmediata a contactos de emergencia predefinidos.

El sistema integra tres componentes clave:

- Un módulo de clasificación acústica que utiliza modelos preentrenados como YAMNet y Vosk para identificar sonidos y palabras clave.
- Un módulo de detección de anomalías basado en modelos de inteligencia artificial como LSTM e Isolation Forest, que analiza secuencias de sonidos para identificar comportamientos atípicos.
- Un módulo de notificaciones que envía alertas en tiempo real a través de Telegram, correo electrónico o SMS.

Este manual contiene las instrucciones necesarias para interactuar con el sistema, comprender sus señales y responder adecuadamente en diferentes situaciones.

### Desarrolladores del sistema

El Sistema de Monitoreo Acústico fue desarrollado por los tesisas Carmelo Naim y César Sotillo, estudiantes de Ingeniería Informática de la Universidad Católica Andrés Bello, como parte de su Trabajo de Grado, realizado entre 2024 y octubre de 2025.

## Requisitos previos

Antes de comenzar a utilizar el sistema, asegúrese de cumplir con los siguientes requisitos:

Conocimiento previo:

- No se requieren conocimientos técnicos avanzados.
- Es recomendable familiarizarse con los comandos de voz que el sistema reconoce.

Requisitos del sistema:

- Hardware: Dispositivo Raspberry Pi 4, micrófonos USB, conexión estable a internet y energía eléctrica continua
- Software: Aplicación de mensajería Telegram instalada en el teléfono del usuario o contacto designado.
- Red: Conexión Wi-Fi o Ethernet.

## Requisitos previos

El sistema opera de manera autónoma y no requiere una interfaz gráfica para su funcionamiento cotidiano. Sin embargo, el usuario puede interactuar con él mediante comandos de voz y recibir notificaciones.

Componentes principales:

- Agentes de audio: Programas que escuchan continuamente el ambiente y clasifican sonidos.
- Sistema de alertas: Envía notificaciones automáticas cuando detecta una posible emergencia.
- Interacción por voz: Permite al usuario cancelar alertas o confirmar su estado.

Flujo de interaccion:

- El agente de audio escucha continuamente el ambiente.

- Al detectar un sonido clasifica.
- Si se identifica una anomalia, se activa el sistema de alertas.
- El usuario recibe una notificación.
- El usuario puede interactuar por voz para cancelar la alerta y confirmar su estado.

## Problemas comunes

A continuación, se presentan algunos problemas que pueden surgir durante el uso del sistema y sus posibles soluciones:

### 1. El sistema no responde a comandos de voz

- Causa: Ruido ambiental alto o micrófono obstruido.
- Solución: Hable en un tono claro y dirigido hacia el micrófono. Reduzca el ruido de fondo si es posible.

### 2. Falsos positivos

- Causa: El sistema puede estar interpretando eventos comunes como anomalías.
- Solución: Cancela la alerta usando el comando de voz .<sup>Es</sup>toy bien”.

### 3. No se reciben notificaciones en Telegram

- Causa: Problemas de conexión a Internet.
- Solución: Verifique la conexión a Internet.

## Notas importantes

- Asegúrese de que el micrófono esté correctamente conectado y configurado en su dispositivo. Además de estar colocado en un lugar adecuado para captar el sonido.
- Mantenga el software del sistema actualizado el software del sistema para mejorar la precisión en la detección.

- El sistema no almacena grabaciones de audio. Todo el procesamiento se realiza de forma local y en tiempo real.

## Apéndice F. Manual de Sistema

### Introducción

El siguiente documento es la guía de instalación de Alertify, un sistema de monitoreo acústico inteligente diseñado para la identificación de sonidos ambientales y la generación automática de alertas ante eventos sonoros anómalos que puedan indicar una situación de emergencia o vulnerabilidad.

El sistema está especialmente orientado a entornos domésticos o asistidos, proporcionando una solución no invasiva para el monitoreo continuo de personas que puedan requerir asistencia inmediata, como adultos mayores, personas con discapacidad o cualquier individuo en situación de riesgo.

La arquitectura del sistema se compone de los siguientes módulos principales:

1. **Agentes de captura y detección**, que ejecutan modelos especializados de inteligencia artificial para:

- Reconocimiento de voz en tiempo real (Vosk)
- Clasificación de eventos acústicos (YAMNet)
- Detección de anomalías en secuencias sonoras (LSTM, Transformer, Isolation Forest)
- Monitoreo de períodos de silencio prolongado (Silents Agent)
- Persistencia de eventos (Data Agent)
- Gestión de notificaciones de emergencia (Emergency Agent)

La arquitectura está realizada para operar en dispositivos de edge computing como el Raspberry Pi 4 modelo B, garantizando que el procesamiento de audio se realice de forma local y privada, sin almacenar grabaciones ni depender de servicios en la nube para el análisis sensible.

Este manual está dirigido a administradores de sistemas y usuarios técnicos, y proporciona instrucciones completas para la instalación, configuración, operación y resolución de problemas.

## Requisitos

### Hardware

1. Raspberry Pi 4 Modelo B con las siguientes especificaciones:
  - Procesador: Broadcom BCM2711, SoC de cuatro núcleos Cortex-A72 (ARM v8) de 64 bits a 1,8 GHz
  - Memoria Ram: 4GB
  - Almacenamiento: MicroSD 32GB Clase 10 o superior
  - Puertos: 2 × USB 3.0, 2 × USB 2.0, 2 × micro-HDMI
  - Audio: Entrada de micrófono via USB
  - Microfonos: Adafruit Mini Microfono USB 3367

### Software

1. Raspberry Pi 4 Modelo B:
  - Sistema operativo: Raspberry Pi OS (64-bit) Bullseye o superior
  - Python: Versión 3.9 o 3.10
  - Librerías a utilizar: pandas, joblib, scikit-learn, tensorflow, numpy, sounddevice, python-socketio, pyaudio, vosk, aiohttp, psycopg2, aioredis, pyttsx3

### Infraestructura de red

1. Puertos requeridos
  - Redis: 6379
2. Conectividad
  - Red local estable entre Raspberry Pi y servidor
  - Acceso a internet para notificaciones externas (Telegram, SMTP)

## **Modelo de IA y recursos.**

### **1. Modelos Preentrenados**

- Yamnet: yamnet-agent/yamnet.tflite, yamnet-agent/yamnet\_class\_map.csv
- VOSK (español): vosk-agent/vosk-model-small-es-0.42/
- Modelo de Anomalías:
  - a) lstm-agent/lstm\_autoencoder.keras y lstm-agent/umbral.pkl

### **2. Conectividad**

- Red local estable entre Raspberry Pi y servidor
- Acceso a internet para notificaciones externas (Telegram, SMTP)

## **Instalación**

### **Cliente (alertify-client).**

1. Clonar y abrir carpeta Alertify-client.
2. Verificar Python 3.9+ y crear un entorno virtual (opcional).
3. Asegurar que los siguientes modelos estén en sus rutas correspondientes.
4. Ejecutar los agentes y scripts principales

## **Configuración**

### **Redis**

Los agentes usan por defecto redis://default:alertify@localhost:6379. Si cambia el host o las credenciales, actualice los scripts o variables de entorno correspondientes.



## Configuración de audio

En `silents-agent/silents-agent.py`, verificar y ajustar según sea necesario:

- `SAMPLE_RATE`
- `VARIANCE_THRESHOLD`
- Otros parámetros relacionados con la captura de audio

## Carpetas y Archivos (`alertify-client`).

### Archivos en la raíz

Componentes principales para orquestar y documentar el cliente.

Archivo	Descripción
<code>main.py</code>	Lanza los agentes como procesos independientes, maneja señales de parada y espera su finalización.
<code>README.md</code>	Introducción y notas del cliente
<code>requirements.txt</code>	Lista de dependencias Python necesarias para ejecutar los agentes (pandas, tensorflow, aioredis, vosk, etc.).
<code>.gitignore</code>	Reglas de exclusión de Git (archivos temporales, modelos, entornos, etc.).

### CSV

Catálogos en CSV utilizados por agentes de audio para mapear clases y categorías.

Archivo	Descripción
Clasificación de categorías.csv	Tabla de categorías de eventos/sonidos normalizados para etiquetado y análisis.
yamnet_class_map.csv	Etiqueta legible de YAMNet usado por el agente de clasificación.

### **data\_agent**

Ingesta de eventos desde Redis, persistencia en PostgreSQL y generación periódica de dataset

Archivo	Descripción
config.py	Lee data_agent/database.ini con ConfigParser y devuelve un dict de conexión PostgreSQL.
data_agent.py	Suscribe a Redis (alertas_audio, alertas_vosk), inserta eventos en tabla event y actualiza data/dataset.csv periódicamente.
generate_csv.py	Genera data/dataset.csv on-demand; normaliza zona horaria (America/Caracas) y guarda fechas sin tz.
postgres_connection.py	Gestiona una conexión global a PostgreSQL con psycopg2 usando la configuración cargada.

### **emergency\_agent**

Agente que gestiona las alertas de emergencia.

Archivo	Descripción
emergency_agent.py	Se suscribe a múltiples canales Redis, agrega alertas, permite pausar/reanudar, hace TTS y envía notificaciones a Telegram; expone control por vosk_commands / emergency_control.

### Isolation-forest-agent

Detección de anomalías de secuencias de eventos con Isolation Forest.

Archivo	Descripción
encoder.pkl	Codificador para transformar etiquetas de eventos a vectores.
isolation-forest-agent.py	Escucha alertas_audio, construye features temporales (día/tiempo cíclico), detecta anomalías por batch y publica en alertas_isolation_forest; si falta modelo, entrena y guarda anomalies_model.pkl.

### lstm-agent

Detección de anomalías con Autoencoder LSTM en ventanas temporales

Archivo	Descripción
encoder.pkl	Codificador para transformar etiquetas a vectores de entrada del modelo.
lstm_autoencoder.keras	Modelo Keras de Autoencoder LSTM.
lstm-agent.py	Consume alertas_audio, arma secuencias (longitud fija), calcula MSE de reconstrucción y publica series anómalas en alertas_lstm si supera el umbral.
umbral.pkl	Umbral de MSE recomendado para lstm_autoencoder.keras.

### **silent-agent**

Detección en tiempo real de silencio/actividad a partir de audio del micrófono.

Archivo	Descripción
silents-agent.py	Captura audio, calcula varianza por frame, aplica ventana de estabilidad y periodo de retención, y publica cambios de estado (silencio/actividad) en alertas_silencio con métricas.

### **Vosk-agent**

Reconocimiento de voz offline con Vosk en español y disparo de eventos por palabras clave.

Archivo	Descripción
vosk-agent.py	Escucha micrófono con sounddevice y Vosk, detecta palabras clave (auxilio/Estoy bien), publica en alertas_vosk y envía comandos a vosk_commands.

**Vosk-model-small-es-0.42**

<b>Archivo</b>	<b>Descripción</b>
README	Información del modelo y notas del proyecto Vosk.
am/final.mdl	Modelo acústico entrenado (acoustic model).
conf/mfcc.conf	Configuración de extracción de características MFCC.
conf/model.conf	Configuración general del modelo.
graph/disambig_tid.int	Archivo de desambiguación para el grafo de decodificación.
graph/Gr.fst	Grafo FST principal para decodificación.
graph/HCLr.fst	Composición HCL para el decodificador (fonética/lexicón).
graph/phones/word_bounday.int	Límites de palabras por audio.
ivector/final.dubm	UBM para i-vectors.
ivector/final.ie	Extracción de i-vectors.
ivector/final.mat	Matriz de proyección para i-vectors.
ivector/global_cmvn.stats	Estadísticas para normalización CMVN global.
ivector/online_cmvn.conf	Configuración CMVN online.
ivector/splice.conf	Configuración de splicing de características.

**Yamnet-agent**

Clasificación de audio en streaming con YAMNet (TensorFlow Lite) y publicación de eventos.

Archivo	Descripción
yamnet.class_map.csv	Archivo con el nombre de cada clase para interpretar predicciones.
yamnet-agent.py	Captura audio, infiere con TFLite, marca emergencias por índices críticos y publica eventos en alertas_audio.
yamnet.tflite	Modelo YAMNet en formato TensorFlow Lite usado por el agente.

## Carpetas y Archivos (alertify-server).

### Archivos en la raíz

Archivos base de configuración, tooling y metadatos del proyecto NestJS/TypeORM.

Archivo	Descripción
package.json	Scripts de desarrollo/producción (Nest, TypeORM, seeds), dependencias y configuración de Jest.
pnpm-lock.yaml	Bloqueo de dependencias (pnpm).
docker-compose.yml	Servicios contenedorizados (p.ej. PostgreSQL/Redis si aplica) para desarrollo.
nest-cli.json	Configuración del CLI de Nest (paths de compilación).
tsconfig.json	Configuración TypeScript principal.
tsconfig.build.json	Configuración TypeScript para compilación a producción (dist).
.eslintrc.js	Reglas de ESLint.
.prettierrc	Reglas de formateo Prettier.
.gitignore	Exclusiones de Git.
README.md	Documentación del servidor.

## SRC

Código fuente del servidor (NestJS), organizado por módulos y configuración.

Archivo	Descripción
main.ts	Inicializa contexto transaccional, configura Swagger en /docs, prefijo api/v1 y levanta el servidor en PORT.
app.module.ts	Carga .env, registra TypeORM y el módulo Events, habilita @nestjs/schedule.
config/	Configuración de entorno y base de datos (TypeORM, DataSource, variables).
modules/	Módulos de funcionalidad (actualmente events).

### src/config

Configuraciones de entorno y base de datos

Archivo	Descripción
environment.ts	Cargar variables desde .env y las exporta como objeto envConfig.
database.config.ts	Opciones DataSourceOptions para PostgreSQL: host/puerto/credenciales/DB, entities, synchronize, migraciones y timezone.
database.ts	Vuelve a exportar propiedades básicas de conexión a DB a partir de environment.
datasource.config.ts	Instancia DataSource (TypeORM) desde database.config para migraciones/CLI.
typeorm.config.ts	Config asíncrono de TypeORM para Nest; integra typeorm-transactional con addTransactionalDataSource.

**src/modules/events**

Módulo responsable de WebSockets (Socket.IO), gestión de eventos, emergencias, actividad y configuración de alarmas.

Archivo	Descripción
events.gateway.ts	Gateway WebSocket: maneja conexión/desconexión, comandos im-ok, help-call, alarmOn/Off, emite emergency-alert y reproduce TTS (voz).
events.service.ts	Lógica de negocio: CRUD de eventos/emergencias, cron jobs para silencios y emergencias, y notificaciones (Telegram/Email/TTS).
enums/events.enums.ts	Enumeración Calls para tipos de llamadas (imOk, helpCall).

**Links a los repositorios**

1. Alertify-client: <https://github.com/Cariea/alertify-client>
2. Alertify-server: <https://github.com/Cariea/alertify-server>